

Pronóstico de ventas para toma de decisiones en comercio electrónico usando machine learning

Ing. Jonathan Matias Borda

Carrera de Especialización en Inteligencia Artificial

Director: Dr. Diego Onna (Universidad de Buenos Aires)

Jurados:

Esp. Ing. Cristian Patricio Salinas Talamilla (FIUBA)

Dr. Facundo A. Lucianna (FIUBA)

Esp. Ing. Michael Andrés Arredondo Mendoza (FIUBA)

Ciudad de Buenos Aires, junio de 2026

Resumen

En la presente memoria se describe el desarrollo de un modelo de inteligencia artificial para el pronóstico de ventas en la tienda en línea de la empresa Latech [1], dedicada a la producción y comercialización de barritas alimenticias. El trabajo tiene como finalidad mejorar la planificación de la producción y facilitar la gestión del inventario y toma de decisiones estratégicas en la empresa.

Para su realización se aplicaron conocimientos de análisis de datos, modelado de series temporales, aprendizaje automático, integración de APIs y desarrollo de software.

Índice general

Resumen	I
1. Introducción general	1
1.1. Contexto y motivación	1
1.2. Estado del arte	2
1.3. Objetivo y alcance	3
1.3.1. Objetivo del trabajo	4
1.3.2. Alcance del trabajo	4
2. Introducción específica	7
2.1. Requerimientos	7
2.2. Modelos de inteligencia artificial utilizados	8
2.3. Tratamiento de datos (herramientas)	9
2.3.1. Bibliotecas para procesamiento y análisis de datos	9
2.3.2. Bibliotecas para visualización	9
2.3.3. Plataformas y APIs externas	9
2.3.4. Exposición de servicios	10
2.3.5. Contenerización	10
2.3.6. Orquestación y pipelines	10
3. Diseño e implementación	13
3.1. Arquitectura del sistema	13
3.1.1. Capa de recolección de datos	14
3.1.2. Capa de procesamiento y transformación	15
3.1.3. Capa de almacenamiento estructurado	16
3.1.4. Capa de modelado predictivo	17
3.1.5. Capa de integración operativa con microservicios	18
3.1.6. Capa de visualización y consumo dentro de Inventory Tracker	18
3.1.7. Justificación global de la arquitectura	19
3.2. Automatización mediante tareas programadas	19
3.3. Análisis de datos	20
3.3.1. Limpieza y Normalización de la Información	20
3.3.2. Estrategias de Imputación y Gestión de Inconsistencias	20
3.3.3. Ingeniería de Características (<i>Feature engineering</i>)	21
3.4. Desarrollo de modelos	22
3.4.1. Modelo base (<i>baseline</i>): lógica de heurística original	22
3.4.2. Implementación del Framework de Modelado	23
3.4.3. Estrategia de entrenamiento y mitigación de sobre-ajuste	23
3.5. Desarrollo de un <i>framework</i> modular	24
3.5.1. Estandarización de interfaces y orquestación mediante DAGs	24
3.5.2. Lógica de competencia y selección automática del modelo	24
3.6. Despliegue con microservicios e integración con bases de datos	25

3.6.1.	Estrategia de contenerización y orquestación	27
3.6.2.	Arquitectura de microservicios e integración operativa . . .	27
3.6.3.	Integración con la capa de persistencia y servicios externos	27
4.	Ensayos y resultados	29
4.1.	Ensayos de modelos	29
4.2.	Desempeño de los modelos	30
4.3.	Desempeño de la predicción	31
4.3.1.	Precisión general y sesgo	32
4.3.2.	Análisis de <i>outliers</i>	33
4.3.3.	Estabilidad y Confiabilidad	33
4.4.	Comparación de algoritmos	34
4.4.1.	Predicciones de Neural prophet	34
4.4.2.	Predicciones de TFT	35
5.	Conclusiones	37
5.1.	Resultados obtenidos	37
5.2.	Trabajo futuro	37
	Bibliografía	39

Índice de figuras

3.1. Diagrama Entidad-Relación. Muestra las dos tablas principales. . .	17
3.2. Flujo lógico de orquestación de DAGs.	25
3.3. Diagrama de arquitectura del sistema.	26
4.1. Distribución de las ordenes.	31
4.2. RMSE Neural prophet.	32
4.3. RMSE TFT.	33
4.4. RMSE <i>Baseline</i>	34
4.5. Comparativa de predicciones vs. valores reales: Mezcla lineal frente a Baseline.	35
4.6. Comparativa de predicciones vs. valores reales: Mezcla lineal frente a TFT.	35
4.7. Comparativa de predicciones vs. valores reales: Mezcla lineal frente a Baseline.	36

Índice de tablas

4.1. Comparativa de métricas de desempeño por modelo	30
4.2. Comparativa de métricas de desempeño por modelo	36

Capítulo 1

Introducción general

En este capítulo se presenta el contexto general del trabajo y la problemática que motivó su desarrollo. Se exponen las razones y necesidades que impulsaron su realización, junto con una descripción de las soluciones existentes y los enfoques actuales relacionados con la temática abordada. Asimismo, se detallan los propósitos principales del trabajo y se delimitan los alcances y límites de su implementación.

1.1. Contexto y motivación

El presente trabajo forma parte de la Carrera de Especialización en Inteligencia Artificial y tiene como propósito el desarrollo de un modelo capaz de pronosticar las ventas de una tienda en línea perteneciente a la empresa Latech [1]. Esta compañía fabrica y comercializa barritas alimenticias en distintos sabores, lo que exige una planificación de producción precisa para evitar tanto faltantes como excedentes de stock. En este contexto, disponer de pronósticos confiables de ventas representa un factor estratégico para las decisiones operativas y comerciales.

La empresa ofrece siete sabores considerados productos base, disponibles de forma permanente, y además introduce ediciones limitadas que agregan entre dos y cuatro variantes nuevas por año. Estas ediciones dependen del nivel de aceptación del público y permanecen activas solo mientras alcanzan un volumen de ventas satisfactorio. El producto se vende en paquetes de 10, 20 y 30 unidades, con un precio por unidad que disminuye a medida que aumenta el tamaño del paquete. Asimismo, el sitio ofrece al usuario la opción de suscribirse, lo que permite recibir el producto mensualmente con un descuento aproximado del 10 %. Este sistema facilita la construcción de patrones de demanda asociados a consumos recurrentes y posibilita el análisis del ciclo de vida de las suscripciones, incluyendo altas, bajas y reactivaciones.

Latech lanza cada nueva variante de sabor mediante campañas simultáneas en sus canales de comunicación, como TikTok [2], Instagram [3], Facebook [4] y Google [5]. Estos lanzamientos producen un aumento significativo en la actividad comercial y suelen duplicar las ventas de la nueva variante en comparación con los productos restantes. Un comportamiento similar aparece durante eventos promocionales, como *Black Friday*, donde la aplicación de descuentos generales genera un incremento promedio cercano al 20 % en las ventas totales. Estas fluctuaciones introducen picos marcados en la demanda, cuya anticipación resulta crucial para coordinar producción, logística y abastecimiento.

Antes del desarrollo de este sistema, la empresa no contaba con un mecanismo de pronóstico capaz de anticipar estos cambios de manera sistemática. Las variaciones abruptas en la demanda, especialmente las derivadas de campañas exitosas, superaban en ocasiones la capacidad inmediata de producción. En consecuencia, la organización registraba episodios de quiebre de stock, retrasos en las entregas y deterioro en la experiencia del cliente. La falta de previsión reducía la capacidad de planificar compras de insumos, organizar turnos de producción y definir niveles óptimos de inventario.

La incorporación de datos provenientes de múltiples fuentes permite construir una visión integral del proceso comercial. La empresa utiliza la API de Triple Whale [6] para concentrar la información de inversión publicitaria de TikTok, Instagram, Facebook y Google. Esta información permite identificar qué canales influyen en la conversión, la proporción de usuarios nuevos y recurrentes, y las variaciones en el volumen de ventas según la estrategia de difusión. Por su parte, los datos históricos de ventas extraídos desde Shopify [7] permiten reconstruir la evolución temporal de la demanda, medir el impacto de las ediciones limitadas, cuantificar el efecto de las promociones y analizar patrones estacionales. La combinación de ambas fuentes constituye un insumo esencial para entrenar un modelo de predicción de ventas robusto y contextualizado.

En conjunto, este trabajo apunta a desarrollar un sistema basado en aprendizaje automático que proporcione estimaciones confiables de demanda y que funcione como herramienta de apoyo a la planificación comercial. Su objetivo final consiste en mejorar la toma de decisiones en áreas como producción, abastecimiento, definición de inventarios, activación de campañas y análisis del comportamiento del cliente, que favorezca una gestión más eficiente y orientada a datos.

1.2. Estado del arte

En la actualidad, el pronóstico de ventas mediante técnicas de inteligencia artificial constituye un área de creciente interés en el ámbito del comercio electrónico. Los avances en el análisis de datos y en el aprendizaje automático han permitido la aparición de modelos capaces de anticipar la demanda con altos niveles de precisión, lo que contribuye a una mejor planificación de la producción, la gestión de inventarios y la toma de decisiones estratégicas.

Entre los enfoques más utilizados se encuentran los modelos de series temporales clásicos, como ARIMA [8], SARIMA y *Exponential Smoothing*, que permiten capturar patrones estacionales y tendencias a lo largo del tiempo [9]. Sin embargo, estos métodos presentan limitaciones cuando los datos incluyen múltiples factores externos, tales como campañas publicitarias, variaciones en los precios, promociones o comportamiento del usuario.

En los últimos años se ha observado un aumento significativo en la adopción de técnicas de aprendizaje profundo (*Deep Learning*) y aprendizaje automático (*Machine Learning*), que ofrecen una mayor capacidad para modelar relaciones no lineales y para integrar información proveniente de diversas fuentes. Modelos como Redes Neuronales Recurrentes (RNN), LSTM (*Long Short-Term Memory*) y *Random Forest Regressor* se han aplicado con éxito en la predicción de ventas en entornos de comercio electrónico, debido a su habilidad para capturar dependencias temporales y correlaciones entre variables [10, 11, 12, 13].

De forma más reciente, la literatura destaca los modelos basados en transformadores, como *Temporal Fusion Transformer* (TFT) [14], *Informer* [15] y *N-BEATS* [16], que alcanzaron resultados competitivos en competencias internacionales de series temporales y en aplicaciones industriales. Estos modelos incorporan mecanismos de atención que permiten identificar qué variables externas influyen en la demanda y en qué momentos lo hacen, lo que resulta especialmente relevante en contextos con campañas publicitarias, promociones o cambios abruptos en la visibilidad de los productos.

El interés por evaluar rigurosamente estas técnicas ha impulsado la creación de competencias a gran escala, como M4 y M5 [17], organizadas por la comunidad académica y la industria. Estas competencias demostraron que la combinación de enfoques tradicionales con métodos basados en aprendizaje profundo permite alcanzar mejoras significativas en la precisión de los pronósticos, especialmente cuando los datos provienen de entornos comerciales reales.

Asimismo, el uso de plataformas integradas de datos, tales como *Shopify* [7] y *Triple Whale* [6], permite el desarrollo de soluciones personalizadas que combinan información transaccional, métricas de marketing y comportamiento del usuario. La integración de estas fuentes facilita la incorporación de variables exógenas, como inversión publicitaria, características de los productos, descuentos, actividad de suscripciones o lanzamientos de nuevas variantes. Estas variables contribuyen a mejorar la capacidad predictiva de los modelos.

Entre las soluciones comerciales más reconocidas se destacan *Amazon Forecast* [18], un servicio basado en redes neuronales desarrollado por *Amazon Web Services* [19] que automatiza la creación de modelos de predicción de demanda, y *Prophet* [20], una herramienta de código abierto creada por *Meta* [21] que utiliza un enfoque aditivo para modelar tendencias y estacionalidades de manera flexible. Ambas herramientas representan referencias relevantes en el campo del pronóstico de series temporales con datos de negocios.

La tendencia actual apunta hacia el desarrollo de modelos híbridos que combinen la capacidad de las redes neuronales para capturar relaciones complejas con la interpretabilidad y la robustez de los métodos tradicionales. Esta combinación permite enfrentar entornos caracterizados por factores externos altamente variables, como campañas digitales, promociones estacionales, descuentos temporales o lanzamientos de productos.

En este marco, el trabajo desarrollado se apoya en los enfoques actuales de predicción de demanda mediante aprendizaje automático, datos históricos de ventas, inversión publicitaria y comportamiento del usuario. El objetivo consiste en construir un modelo que represente de forma adecuada las tendencias reales del negocio y que funcione como herramienta de apoyo para la toma de decisiones estratégicas en la empresa *Latech*.

1.3. Objetivo y alcance

En esta sección se mencionan los propósitos principales del trabajo y los límites de su implementación.

1.3.1. Objetivo del trabajo

El propósito de este trabajo es desarrollar un modelo de inteligencia artificial que permita predecir con precisión las ventas del producto alimenticio de la empresa Latech, a partir de datos históricos de ventas y de inversión publicitaria.

Los objetivos específicos incluyen:

- Construir un sistema predictivo que anticipe la demanda para horizontes de pronóstico corto (1 a 6 meses), período crítico para la planificación operativa de la empresa.
- Identificar y cuantificar el impacto de las campañas publicitarias en las ventas mediante mecanismos de atención interpretable.
- Proporcionar a la empresa herramientas para optimizar la planificación de inventario y producción.
- Reducir los riesgos de faltantes y excesos de stock mediante predicciones confiables.
- Establecer una base técnica para la toma de decisiones estratégicas basada en datos.

1.3.2. Alcance del trabajo

A continuación, se enuncian los items que incluye el trabajo:

- Relevamiento y análisis de los datos históricos de ventas de la tienda en línea obtenidos mediante la API de Shopify.
- Relevamiento y análisis de los datos históricos de inversión publicitaria provenientes de la API de Triple Whale.
- Limpieza, transformación y consolidación de datos provenientes de ambas plataformas.
- Análisis exploratorio de datos (EDA) para identificar patrones, tendencias y relaciones entre las variables.
- Desarrollo y entrenamiento de modelos de inteligencia artificial orientados a la predicción de ventas.
- Evaluación comparativa de distintos modelos para seleccionar el que ofrezca la mejor precisión y capacidad predictiva.
- Implementación de un módulo funcional integrado al sistema Inventory Tracker de la empresa, que permita realizar predicciones de ventas para períodos futuros.
- Documentación técnica del proceso, del modelo elegido y de su uso.
- Entrega de reportes que expliquen los hallazgos y recomendaciones derivadas del análisis.

Por otra parte, quedan excluidas del alcance las siguientes actividades:

- Implementaciones en tiempo real del modelo, es decir, sistemas que actualicen las predicciones de forma instantánea ante cada nuevo dato recibido. Sí

se contempla la posibilidad de programar ejecuciones periódicas del modelo (por ejemplo, una vez al día) para actualizar las predicciones de manera regular.

- Garantía de precisión absoluta en las predicciones, ya que la precisión depende de la calidad y estabilidad de los datos futuros y de factores externos no controlables.
- Acciones o recomendaciones específicas sobre estrategias de marketing más allá de lo inferido de los análisis de datos.
- Re-ingeniería de procesos operativos internos de producción o logística.
- Optimización de procesos internos de producción o logística, salvo en lo que respecta a la estimación de demanda.

Capítulo 2

Introducción específica

En este capítulo se presentan los requerimientos más importantes, los modelos de inteligencia artificial utilizados y las herramientas usadas para el tratamiento de datos.

2.1. Requerimientos

En esta sección se presentan algunos requerimientos establecidos para el trabajo. En cada requerimiento se detalla su objetivo y alcance, con el fin de precisar las condiciones necesarias para el desarrollo y la correcta implementación del modelo propuesto.

- Importación de datos de ventas desde Shopify: el sistema debe permitir la obtención de datos históricos y actualizados de ventas desde la plataforma Shopify, con el objetivo de utilizarlos en el proceso de entrenamiento del modelo de predicción de demanda.
- Importación de datos de inversión publicitaria desde Triple Whale: el sistema debe permitir la incorporación de datos de inversión publicitaria provenientes de la plataforma Triple Whale, con el propósito de integrar esta variable en el análisis y modelado de ventas.
- Consolidación de datos provenientes de Shopify y Triple Whale: el sistema debe unificar la información de ventas y de inversión publicitaria en un único conjunto de datos, con el fin de preparar una base consistente para el entrenamiento del modelo de predicción.
- Desarrollo y entrenamiento del modelo predictivo: el sistema debe implementar y entrenar un modelo de inteligencia artificial capaz de generar predicciones de ventas precisas sobre los datos históricos consolidados.
- Visualización de predicciones de ventas en Inventory Tracker: el sistema debe presentar las predicciones de ventas generadas por el modelo dentro de la plataforma Inventory Tracker, integradas con los datos históricos para facilitar el análisis y la planificación de producción.
- Descarga de predicciones de ventas en formato CSV: el sistema debe permitir la exportación de las predicciones de ventas a archivos CSV para su análisis externo o integración con otras herramientas de planificación.

2.2. Modelos de inteligencia artificial utilizados

Para abordar el trabajo se evaluaron y aplicaron diversos modelos de inteligencia artificial, dado que el comportamiento de la demanda no responde a un único patrón fijo ni puede ser capturado adecuadamente por un solo tipo de modelo. También, se consideró seleccionar aquel que ofreciera el mejor equilibrio entre precisión, interpretabilidad y capacidad de generalización.

A continuación, se describen los tipos de modelos aplicados:

- Random Forest Regressor [22]: se utilizó por su robustez frente a sobreajuste y su capacidad para capturar relaciones no lineales entre variables. Este modelo resulta especialmente útil cuando se integran múltiples fuentes de datos, como ventas históricas e inversión publicitaria.
- Gradient Boosting Machines [23] (XGBoost, LightGBM): se evaluaron por su alto rendimiento en competencias de ciencia de datos y su eficiencia computacional. Estos modelos permiten optimizar la función de pérdida de manera iterativa y mejorar la precisión en la predicción de series temporales con características externas.
- SARIMA (*Seasonal Autoregressive Integrated Moving Average*): se aplicó para modelar la estacionalidad y tendencia presentes en los datos de ventas. SARIMA es especialmente efectivo cuando el comportamiento temporal es predominante y estable a lo largo del tiempo.
- *Exponential Smoothing* (ETS) [24]: se consideró como alternativa para capturar patrones estacionales y de tendencia con un enfoque más intuitivo y menos paramétrico que SARIMA.
- *Long Short-Term Memory* (LSTM): se implementaron redes LSTM debido a su habilidad para retener información a largo plazo y modelar dependencias temporales complejas. Este tipo de red es adecuado para series temporales con patrones no lineales y múltiples variables exógenas, como la inversión publicitaria por plataforma.
- GRU (*Gated Recurrent Unit*) [25]: se evaluó como una variante más simple y computacionalmente eficiente de las LSTM, útil cuando los recursos de entrenamiento son limitados. Además, mantienen la capacidad esencial de capturar dependencias temporales a largo plazo y manejar el problema del gradiente *vanishing*, que en ocasiones demuestra un desempeño comparable al de las LSTM.
- *Temporal Fusion Transformer* (TFT): Se implementó este modelo de vanguardia por su capacidad de atención interpretable, que permite identificar qué variables exógenas y qué períodos históricos influyen en cada predicción. El TFT resulta particularmente adecuado para el contexto de Latech, donde es crucial entender el impacto de las inversiones publicitarias en diferentes horizontes temporales.
- Enfoque híbrido: se exploró la combinación de modelos clásicos (como SARIMA) con redes neuronales (como LSTM o TFT), con el fin de aprovechar la capacidad de los primeros para modelar componentes estacionales y de tendencia, y la flexibilidad de las segundas para capturar relaciones no lineales y efectos de variables externas.

- Prophet: se incluyó el modelo Prophet, desarrollado por Meta [21], por su facilidad de uso y capacidad para manejar estacionalidades múltiples, días festivos y cambios en la tendencia. Este modelo resultó de interés para validar la estructura temporal de los datos antes de aplicar modelos más complejos.

Cada uno de estos modelos fue entrenado y validado utilizando el conjunto de datos consolidado de ventas e inversión publicitaria, y se compararon mediante métricas como MAE (error absoluto medio), RMSE (raíz del error cuadrático medio) y MAPE (error porcentual absoluto medio), con el fin de seleccionar el que mejor se adaptara a las necesidades de pronóstico de Latech.

2.3. Tratamiento de datos (herramientas)

En esta sección se describen los procesos y herramientas utilizadas para la limpieza, transformación y análisis de los datos, así como los recursos externos desarrollados por terceros que resultaron fundamentales para la obtención y procesamiento de la información.

2.3.1. Bibliotecas para procesamiento y análisis de datos

- Pandas [26]: permite manipular y transformar datos tabulares, incluidas operaciones de filtrado, agrupamiento y combinación de datasets.
- NumPy [27]: ofrece operaciones numéricas y manejo eficiente de arreglos multidimensionales.
- Scikit-learn [28]: empleada para el preprocesamiento de datos (escalado, codificación de variables categóricas) y la implementación de modelos clásicos de *machine learning*.
- Pytorch [29]: framework que permite definir arquitecturas personalizadas, calcular gradientes automáticamente y realizar entrenamientos acelerados mediante GPU. Su integración con bibliotecas como NumPy, Pandas y Matplotlib facilita incorporarlo a flujos de trabajo existentes y explorar modelos predictivos más sofisticados que los basados únicamente en series temporales clásicas.

2.3.2. Bibliotecas para visualización

- Matplotlib [30] y Seaborn [31]: permiten generar gráficos estáticos que facilitan la identificación de patrones, tendencias y valores atípicos.
- Plotly [32]: utilizado para la creación de visualizaciones interactivas dentro de los notebooks.

2.3.3. Plataformas y APIs externas

- Shopify API [7]: proporciona acceso automatizado a datos históricos de ventas, productos y transacciones.
- Triple Whale API [6]: ofrece datos de inversión publicitaria desglosados por plataforma y campaña.

- PostgreSQL [33]: funciona como sistema de gestión de bases de datos destinado al almacenamiento estructurado de los datos consolidados.
- Cron [34]: permite ejecutar tareas programadas a horas, fechas o intervalos fijos periódicos para automatización de *pipelines*.
- AWS S3 [35]: ofrece un servicio de almacenamiento de objetos en la nube de AWS que con alta escalabilidad, disponibilidad, durabilidad y seguridad necesarios para guardar los modelos y datos intermedios.
- Git [36]: sistema de control de versiones distribuido que mantiene un registro histórico de cambios en archivos de código, configuraciones y documentación, esencial para el desarrollo colaborativo y la reproducibilidad de experimentos.

2.3.4. Exposición de servicios

Para exponer endpoints que permiten consumir resultados, ejecutar procesos o servir modelos se utiliza FastAPI. Este framework destaca por su alto rendimiento y por su arquitectura asíncrona basada en ASGI [37].

Las características más relevantes para este proyecto son:

- Alto rendimiento: maneja múltiples solicitudes de manera eficiente gracias a su soporte nativo para operaciones asíncronas.
- Validación y documentación automática: incorpora Pydantic [38] para validar estructuras de entrada y genera documentación OpenAPI/Swagger [39] sin requerir configuraciones adicionales.
- Flexibilidad: permite definir endpoints destinados al consumo de modelos, consultas filtradas, refresco de datos o ejecución de procesos administrativos.

2.3.5. Contenerización

- Docker [40]: permite definir entornos de ejecución consistentes para los servicios del proyecto. Sus contenedores aseguran reproducibilidad, aislamiento y portabilidad entre distintos entornos.
- Docker compose [41]: herramienta que simplifica la orquestación de múltiples contenedores Docker mediante archivos de configuración en formato YAML. Permite la definición y ejecución de aplicaciones multi-servicio de manera coordinada, lo que facilita la puesta en marcha de entornos complejos que incluyen la API de FastAPI, la base de datos PostgreSQL y servicios auxiliares de forma integrada. Docker Compose maneja automáticamente las dependencias entre servicios, las redes virtuales y los volúmenes de persistencia.

2.3.6. Orquestación y pipelines

- Metaflow [42]: se utiliza como herramienta principal para estructurar y ejecutar pipelines de datos y experimentos, con registro automático de artefactos y trazabilidad.

- Apache Airflow [\[43\]](#): framework de orquestación que define flujos de trabajo como DAGs (*Directed Acyclic Graphs*) [\[44\]](#) y permite programar ejecuciones periódicas, manejar dependencias entre tareas y monitorizar el estado de los procesos de datos.

Capítulo 3

Diseño e implementación

En este capítulo se describen los criterios utilizados para la construcción del desarrollo y la arquitectura definida para la solución. Se presenta la estructura general del sistema, las decisiones de diseño adoptadas y los componentes que permiten integrar fuentes de datos externas, procesarlas y generar pronósticos confiables de ventas.

3.1. Arquitectura del sistema

La arquitectura diseñada para el sistema de predicción de ventas se basa en un flujo de procesamiento secuencial y automatizado que conecta las fuentes de datos externas con el entorno interno del cliente. El diseño se orientó por tres criterios principales:

- Centralización y coherencia de datos. Se priorizó la unificación de múltiples fuentes (ventas, comportamiento de usuarios, inversión en publicidad).
- Escalabilidad operativa que permita que el sistema integre nuevos canales, nuevas métricas o nuevos modelos sin alterar la estructura existente.
- Procesos reproducibles y auditables para asegurar que cada etapa sea trazable y que el sistema pueda ser mantenido o ampliado por equipos técnicos futuros.

El sistema se organiza en una arquitectura por capas que separa claramente las responsabilidades, desde la obtención de los datos hasta la entrega del pronóstico al usuario final. Estas capas son:

1. Capa de recolección de datos (Data Ingestion Layer).
2. Capa de procesamiento y transformación (ETL).
3. Capa de almacenamiento estructurado (Data Storage Layer).
4. Capa de modelado predictivo (Modeling Layer).
5. Capa de integración operativa mediante microservicios.
6. Capa de visualización y consumo dentro de sistema Inventory Tracker.

Cada una de estas capas se comunica de manera acotada mediante APIs internas o a través de la base de datos para garantizar un bajo acoplamiento.

3.1.1. Capa de recolección de datos

Esta capa se encarga de conectarse periódicamente a APIs externas para obtener la información necesaria para entrenar y actualizar los modelos. Las dos fuentes externas son:

- **Shopify:** funciona como el pilar central de la información comercial del sistema. A través de su API es posible acceder a los históricos de ventas, que incluye detalles como: estado, valor total y descuentos. Además, cada orden incluye etiquetas que permiten distinguir si la compra corresponde a un cliente nuevo o recurrente, lo que posibilita analizar el comportamiento de los usuarios a lo largo del tiempo. Esta distinción es un insumo clave para: caracterizar patrones de fidelidad, frecuencia de compra y recurrencia. A partir de la combinación de órdenes, etiquetas de comportamiento y series temporales de ventas, se logra reconstruir el ciclo completo de los clientes y diferenciar entre la demanda estable generada por suscriptores activos y la demanda variable asociada a compras espontáneas o impulsadas por campañas de marketing.
- **Triple Whale:** una plataforma que centraliza la información de inversión publicitaria proveniente de TikTok Ads [2], Instagram Ads [3], Facebook Ads [4] y Google Ads [5]. En este caso, la API no provee datos desagregados de campañas individuales, sino únicamente el monto diario total invertido en publicidad que considera todas las campañas activas. A pesar de esta limitación, esta información resulta suficiente para analizar la relación entre los niveles diarios de inversión publicitaria y las variaciones observadas en las ventas. De esta forma, el gasto diario consolidado funciona como un indicador de la presión publicitaria ejercida en cada jornada, lo que permite estudiar su impacto en el comportamiento de compra y en la demanda general del sistema.

Ambas integraciones están preparadas para ejecutarse en un proceso automatizado que consulta las APIs diariamente y almacena la información en una base de datos PostgreSQL [33] interna. Este proceso opera bajo un módulo ETL [45] donde se llevan a cabo tareas de validación, normalización y estandarización para garantizar la coherencia entre fuentes heterogéneas.

La decisión de almacenar localmente los datos en PostgreSQL responde a tres objetivos principales:

- **Autonomía del sistema:** aunque se dispone de acceso a las APIs de Shopify y Triple Whale, estas pueden presentar interrupciones temporales, límites de tasa de consulta (conocido en inglés como *rate limits*) o cambios no anunciados en su estructura. Al mantener una copia local de los datos, el sistema de pronóstico continúa funcionando incluso durante caídas de las APIs externas. Esto garantiza la disponibilidad continua del sistema.
- **Rendimiento y velocidad:** consultar datos históricos desde una base de datos local es significativamente más rápido que realizar múltiples solicitudes HTTP a APIs externas, especialmente cuando se procesan grandes volúmenes de datos durante el entrenamiento de modelos o la generación de informes.
- **Desacoplamiento y control de datos:** al poseer una copia estructurada de los datos, se evita la dependencia directa de la disponibilidad y formato de las

APIs externas. Esto permite realizar transformaciones, enriquecimientos y agregaciones previas que optimizan los procesos posteriores de modelado y análisis.

De esta manera, PostgreSQL actúa como una capa de abstracción y resiliencia, que permite que el sistema opere de manera eficiente, predecible y con menor latencia, sin comprometer su funcionalidad ante eventuales fallos externos.

3.1.2. Capa de procesamiento y transformación

Una vez obtenidos los datos desde las APIs externas, se realiza un proceso de transformación que normaliza y estructura la información. Las principales tareas incluyen:

- Limpieza de campos inconsistentes o incompletos.
- Conversión de formatos de fechas, monedas y valores numéricos.
- Enriquecimiento de datos que combine ventas, comportamiento de usuarios y gasto publicitario.
- Integración de información transaccional con métricas de suscripción.
- Control de duplicados y estandarización de claves primarias.
- Creación de agregaciones temporales diarias.
- Creación de variables derivadas de los datos como medias móviles o ratios de inversión.
- Identificación de picos de campañas.
- Señalización de eventos especiales tales como: promociones, feriados o lanzamientos de productos.
- Integración del estado de suscripciones activas e inactivas.

Este proceso de transformación se implementó mediante DAGs (*Directed Acyclic Graphs*) en Apache Airflow, lo que permite orquestar de manera programada, reproducible y monitorizable cada etapa del *pipeline* de datos.

Los datos intermedios y finales de este proceso se almacenan temporalmente en disco, en un formato estructurado y accesible llamado Parquet, para permitir su reutilización en ejecuciones posteriores sin necesidad de reprocesar desde cero. Este enfoque no solo optimiza el uso de recursos, sino que también facilita la depuración y auditoría de los datos generados en cada etapa.

Dado que Shopify y Triple Whale estructuran sus datos de manera diferente, se construyó un esquema interno unificado que respeta la granularidad diaria necesaria para los modelos de predicción. Este esquema queda materializado en una tabla consolidada dentro de PostgreSQL, lista para su consumo por el módulo de modelado.

La implementación mediante Airflow permite además:

- Ejecución programada o bajo demanda de los flujos de transformación.
- Re-ejecución selectiva de tareas fallidas sin afectar etapas exitosas.
- Monitoreo visual del estado del *pipeline* y alertas ante incidencias.

- Versionado y mantenimiento independiente de la lógica de transformación.

Este módulo permite encapsular toda la lógica de preparación del *dataset* y lo mantiene desacoplado del motor de predicción para que se pueda actualizar fácilmente sin impactar en la generación de pronósticos.

3.1.3. Capa de almacenamiento estructurado

Luego de su procesamiento, los datos se almacenan en una base de datos PostgreSQL diseñada específicamente para consultas analíticas y para servir como fuente unificada de información durante el entrenamiento y evaluación de los modelos. Dentro de esta capa se construye la tabla principal denominada *orders*, en la que se almacena la información proveniente de Shopify ya depurada y enriquecida. Esta tabla contiene las columnas fundamentales para caracterizar el comportamiento de compra de los usuarios:

- *created*: registra la fecha de creación de cada orden.
- *totalPrice*: correspondiente al monto total pagado.
- *customerId*: identifica al cliente.
- *lineItems*: donde se detalla cada producto incluido en la compra junto con sus cantidades.
- *channel*: indica el canal por el cual ingresó la orden.
- *tags*: permite distinguir si la compra corresponde a un cliente nuevo o recurrente mediante etiquetas provistas por Shopify.
- *orderNumberForCustomer*: señala el número de orden que representa dentro del historial del cliente (por ejemplo, un valor igual a 1 implica un cliente nuevo).
- *diffWeeksFromFirstPurchase*: expresa la cantidad de semanas transcurridas desde la primera compra del usuario, lo que permite analizar patrones de frecuencia y retención.

A partir de esta tabla estructurada, se generan columnas derivadas mediante procesos de enriquecimiento en Python, con el objetivo de facilitar el análisis y preparar los datos para su uso en modelos predictivos. Entre estas variables se incluyen:

- *created_weekday*: identifica el día de la semana de cada orden.
- *created_month*: permite estudiar estacionalidades mensuales.
- *unique_customers*: calcula la cantidad de clientes distintos por día.
- *new_customers*: contabiliza cuántos usuarios realizaron su primera compra dentro de cada fecha.
- *returning_customers*: contabiliza cuántos usuarios realizaron más de una compra.

Estas nuevas columnas permiten construir vistas agregadas y analizar la evolución del comportamiento de los clientes en el tiempo.

Finalmente, otra tabla denominada *forecast* consolida la información diaria extraída de TripleWhale. Esta tabla incorpora, entre otras variables, el monto de inversión publicitaria bajo la columna *ad_spend*. La tabla contiene además otros campos utilizados por el sistema Inventory Tracker, derivados de los datos ya existentes. Sin embargo, dichas columnas no forman parte del alcance del presente trabajo, ya que responden a necesidades operativas específicas del cliente y no intervienen en el proceso de modelado.

Este diseño facilita tanto el acceso para entrenamiento de modelos como la consulta rápida desde Inventory Tracker. En la figura 3.1 se muestran las dos tablas principales del trabajo con las columnas que se tomaron en cuenta para este proceso de almacenamiento.




FIGURA 3.1. Diagrama Entidad-Relación. Muestra las dos tablas principales.

3.1.4. Capa de modelado predictivo

Esta capa es responsable del entrenamiento, evaluación y selección de los modelos de pronóstico de ventas. Se implementa un enfoque comparativo donde se ejecutan simultáneamente los modelos mencionados en el capítulo 2.2 (SARIMA, Exponential Smoothing, Random Forest, XGBoost, LightGBM, LSTM y Prophet), con el objetivo de identificar el que ofrezca el mejor desempeño predictivo según las métricas definidas.

El proceso de modelado sigue las siguientes etapas:

1. Entrenamiento múltiple: todos los modelos son entrenados y utilizan el mismo conjunto de datos históricos consolidado y enriquecido.
2. Evaluación y métricas: cada modelo es evaluado con la métrica RMSE para penalizar errores grandes que impactan significativamente en la planificación financiera y de producción.
3. Selección automática: el modelo que obtiene el menor valor de RMSE en el conjunto de validación es seleccionado automáticamente para su uso en producción.
4. Persistencia del modelo: una vez seleccionado, el modelo ganador es serializado y almacenado en un registro de modelos donde queda disponible para su uso en las predicciones futuras.
5. Exposición mediante API: el modelo guardado es integrado en un endpoint REST [46] que forma parte del sistema de microservicios para que el sistema Inventory Tracker consulte las predicciones de ventas en tiempo real.

Este diseño no solo asegura que siempre se esté utilizando el modelo más preciso disponible, sino que también facilita la actualización periódica del mismo mediante reentrenamientos programados. Con cada actualización se mantiene la capacidad predictiva del sistema ante cambios en el comportamiento de las ventas o en las dinámicas de mercado.

3.1.5. Capa de integración operativa con microservicios

La arquitectura del sistema se basa en un enfoque de microservicios, donde cada funcionalidad clave se encapsula en un servicio independiente, desplegado y mantenido de forma aislada. Los microservicios implementados son los siguientes:

- Servicio de ingestión (cronjobs + conectores API).
- Servicio de ETL.
- Servicio de predicción.
- Servicio de API interna para Inventory Tracker.

La comunicación entre estos servicios se realiza mediante endpoints REST internos para operaciones síncronas y, cuando se requiere procesamiento asíncrono o desacoplamiento temporal, a través de colas de mensajería (por ejemplo, con Redis [48]). Este diseño permite que cada servicio evolucione y escale de forma independiente, sin afectar al resto del sistema.

Los principales beneficios de esta capa de microservicios son:

- Actualizaciones incrementales: cada servicio puede ser actualizado, modificado o reemplazado sin impactar en el funcionamiento de los demás, lo que facilita la incorporación de mejoras o nuevas fuentes de datos.
- Escalabilidad selectiva: los módulos con mayor carga computacional, como el servicio de predicción o de ingestión, pueden escalarse horizontalmente de forma independiente para optimizar el uso de recursos.
- Aislamiento de fallos: un fallo en un servicio (por ejemplo, la indisponibilidad temporal de una API externa) no propaga su error al resto del sistema, gracias al desacoplamiento y a los mecanismos de tolerancia a fallos implementados.
- Facilidad de mantenimiento y despliegue: cada servicio cuenta con su propio repositorio, configuración y ciclo de vida, lo que simplifica las tareas de desarrollo, pruebas y despliegue continuo.

3.1.6. Capa de visualización y consumo dentro de Inventory Tracker

Las predicciones de ventas finales se integran en el sistema Inventory Tracker mediante una interfaz intuitiva, la cual permite:

- Solicitar pronósticos para distintos horizontes temporales.
- Visualizar ventas históricas junto con proyecciones.
- Combinar la predicción con datos operativos del cliente como: stock, producción, etc.

Este componente cierra el ciclo de valor al convertir la información generada por el sistema en una herramienta de apoyo para la gestión diaria.

3.1.7. Justificación global de la arquitectura

La arquitectura fue diseñada bajo los siguientes principios:

- Modularidad: permite reemplazar o actualizar partes sin reestructurar toda la solución.
- Escalabilidad: preparada para el aumento del volumen de datos y la posible integración de nuevas plataformas.
- Trazabilidad: indispensable para un sistema basado en machine learning.
- Flexibilidad: permite combinar modelos clásicos, modelos de *machine learning* y eventualmente servicios administrados en la nube.

3.2. Automatización mediante tareas programadas

Para garantizar la operatividad continua y la vigencia de los pronósticos de ventas, se implementó un esquema de automatización integral que elimina la necesidad de intervención manual en los procesos recurrentes. La orquestación de este flujo se fundamenta en el uso de Apache Airflow mediante la definición de grafos acíclicos dirigidos (sus siglas en inglés DAGs), los cuales coordinan la ejecución secuencial y lógica de cada etapa del *pipeline* de datos

Este flujo automatizado permite mantener la información del sistema actualizada de forma oportuna y confiable. Se divide en las siguientes fases operativas:

- Extracción diaria de datos: se ejecuta una conexión automatizada a las APIs de Shopify y Triple Whale para obtener los datos más recientes de ventas e inversión publicitaria. Este proceso garantiza que el sistema opere con información actualizada y evita retrasos en la disponibilidad de datos.
- Actualización del conjunto de datos consolidado: los nuevos datos se procesan, limpian y unifican con el historial existente. Este paso genera un *dataset* integral y consistente que sirve como base para el entrenamiento del modelo y la generación de pronósticos. El sistema incorpora mecanismos de control que evitan la creación de información duplicada para un mismo día. Esta validación automática garantiza que cada jornada cuente con una única entrada consolidada de alta calidad, lo cual previene el doble procesamiento de registros que fueron importados previamente.
- Re-entrenamiento automatizado y seguimiento de experimentos: con una frecuencia programada, el sistema inicia el ciclo de modelado predictivo. En esta fase, se integra una herramienta de gestión del ciclo de vida de *machine learning* (como Metaflow) que registra cada experimento y facilita la trazabilidad de los artefactos generados.
- Selección del modelo óptimo: bajo un enfoque comparativo, el DAG activa el entrenamiento paralelo de diversas arquitecturas, entre las que se incluyen: *XGBoost*, *Catboost*, *Ridge*, *LSTM* y *Temporal Fusion Transformer*. Al finalizar esta etapa, el sistema evalúa el desempeño de cada algoritmo mediante la métrica RMSE. El flujo identifica y selecciona de manera automática el

modelo que presenta el menor error cuadrático medio en el conjunto de validación.

- Persistencia y actualización de predicciones: el modelo ganador se serializa y se almacena en el registro de modelos para su posterior consumo por la API de FastAPI. Posteriormente, se generan los nuevos pronósticos para los horizontes temporales definidos, los cuales actualizan los módulos de visualización en el sistema Inventory Tracker.

La implementación de este ciclo mediante DAGs y herramientas de registro de modelos asegura que el sistema se adapte de forma autónoma a los cambios en las tendencias de ventas o en el comportamiento del mercado. Asimismo, el uso de mecanismos de *logging* en cada tarea permite auditar el funcionamiento del flujo y detectar fallos de manera temprana.

3.3. Análisis de datos

Una vez consolidada la información en la base de datos local, se procedió a realizar un análisis exploratorio de datos con el objetivo de identificar patrones, tendencias y estacionalidades críticas para el modelado predictivo. Este proceso permitió transformar los datos crudos en un *dataset* refinado y apto para el entrenamiento de algoritmos de aprendizaje automático.

3.3.1. Limpieza y Normalización de la Información

Se realizó una fase inicial de saneamiento técnico donde se transformaron los campos de fecha al formato *datetime* y se estandarizaron las magnitudes numéricas para asegurar la coherencia entre las fuentes de Shopify y Triple Whale. Se aplicó un alineamiento temporal exhaustivo para corregir discrepancias de zona horaria entre ambas plataformas y garantizar que la inversión publicitaria diaria correspondiera exactamente al volumen de ventas registrado en el mismo periodo.

3.3.2. Estrategias de Imputación y Gestión de Inconsistencias

La gestión de valores faltantes se abordó mediante criterios diferenciados según la naturaleza de la variable:

- Imputación de valores nulos: en métricas de inversión publicitaria (llamada `ad_spend`), ingresos (`total_revenue`) y volumen de productos vendidos, se aplicó la técnica de imputación por cero (`fillna(0)`). Se determinó que la ausencia de registros en fechas específicas respondía a la inexistencia de actividad comercial o publicitaria, por lo cual el valor cero representó fielmente la realidad del negocio.
- Preservación de registros históricos: en los casos donde una de las fuentes carecía de información, se optó por mantener el registro con valores nulos en lugar de descartarlo, con el fin de evitar la pérdida de información histórica relevante de las demás variables.
- Control de integridad: se implementaron validaciones automáticas para detectar duplicados y campos inconsistentes para asegurar que cada jornada contara con una única entrada consolidada de alta calidad.

3.3.3. Ingeniería de Características (*Feature engineering*)

Para capturar la dinámica compleja de Latech, se generaron nuevas variables que enriquecieron la capacidad predictiva del sistema:

- Variables de estacionalidad: se extrajeron componentes temporales como:
 - `created_weekday`: representa el día de la semana con un valor numérico entre el 0 y el 6, donde 0 equivale al día lunes y el 6 al domingo. Su uso es fundamental para que modelos como Random Forest o XGBoost identifiquen patrones de comportamiento diferenciados entre los días laborables y el fin de semana, periodos donde la actividad comercial de Latech suele presentar variaciones significativas.
 - `created_month`: representa el mes calendario del 1 al 12, donde 1 representa enero y 12 diciembre. Mediante este indicador, los algoritmos analizan la estacionalidad anual y el impacto de periodos de alta demanda, como las festividades o promociones de largo plazo. Esta característica facilita que el modelo *Temporal Fusion Transformer* correlacionen meses específicos con fluctuaciones históricas, lo cual mejora la precisión de los pronósticos en horizontes temporales extendidos.

Estas variables permiten analizar la distribución de la demanda en ciclos semanales y mensuales. Para asegurar una representación exhaustiva, el sistema garantiza la cobertura de los 12 meses del año y los 7 días de la semana, lo que facilita la identificación de patrones de consumo recurrentes en cada periodo.

- Indicadores de dinámica financiera: se incorporó la tasa de variación del ingreso diario mediante el cálculo del cambio porcentual:

```
revenue_growth = totalRevenue.pct_change()
```

Esta variable permite capturar la aceleración o desaceleración de las ventas en comparación con la jornada previa. Su inclusión facilita la detección de tendencias emergentes y picos de demanda que no siempre resultan evidentes al analizar únicamente los valores absolutos de facturación.

- Transformación de ventanas deslizantes (en inglés *sliding window*): se aplicó la función `shift()` para la generación de variables de retraso (conocidas en inglés como *lags*) en el conjunto de datos. A través de este método, el sistema crea pares de características históricas (x) y valores objetivo (y) como:
 - `ad_spend_lag_7`: contiene el gasto en publicidad desplazado 7 días hacia atrás.
 - `ad_spend_lag_30`: contiene el gasto en publicidad desplazado 30 días hacia atrás.
 - `orders_lag_7`: contiene la cantidad de pedidos 7 días hacia atrás.
 - `orders_lag_30`: contiene la cantidad de pedidos 30 días hacia atrás.
- Métricas de comportamiento del cliente: se derivaron indicadores de fidelidad a partir de la actividad transaccional diaria. El sistema identifica el volumen de nuevos compradores mediante el filtrado de registros donde el número de orden del cliente (`order_number_for_customer`) es igual a 1. Esta lógica permite distinguir la primera compra de cada usuario de las

adquisiciones recurrentes. Además, se calculó la cantidad de clientes únicos diarios y la antigüedad del usuario en semanas desde su primera interacción representada con la variable `diff_weeks_from_first_purchase`, lo que aporta información sobre la retención y el ciclo de vida del cliente.

- Señalización de eventos exógenos: se integraron variables binarias para identificar picos de campañas promocionales, lanzamientos de productos y feriados nacionales. El uso de estos indicadores es fundamental, ya que estos eventos duplicaron históricamente las ventas de ciertas variantes y generaron incrementos significativos en la demanda total.

3.4. Desarrollo de modelos

Esta fase del proyecto consistió en la implementación técnica y el ajuste de las arquitecturas encargadas de transformar el conjunto de datos consolidado en proyecciones de demanda. El desarrollo se estructuró a partir de un modelo base heurístico que funcionó como punto de referencia (en inglés *baseline*) frente a la aplicación de diversos algoritmos de aprendizaje automático de mayor complejidad.

3.4.1. Modelo base (*baseline*): lógica de heurística original

Para establecer un nivel de desempeño mínimo aceptable, se formalizó la lógica de cálculo utilizada previamente por la empresa en su sistema Inventory Tracker. Este modelo operó bajo un enfoque estadístico descriptivo que no requirió entrenamiento de parámetros, sino que se basó en el comportamiento histórico inmediato mediante tres métodos principales:

- Promedio móvil (*en inglés trailing mean*): calcula la media de ventas de los últimos siete días previos a la fecha objetivo.
- Mediana por día de la semana (*same weekday median*): identifica el día de la semana correspondiente a la predicción y calcula la mediana de los valores observados para ese mismo día en las últimas ocho semanas.

La predicción final se obtiene mediante un método de mezcla, que aplica una combinación lineal ponderada según la expresión:

$$\text{Predicción} = (0,45 \times \text{TM}_7) + (0,55 \times \text{SW}_8) \quad (3.1)$$

Donde TM es el promedio móvil y SW es la mediana por día de la semana. Este equilibrio permite captar tanto la inercia de la demanda reciente como los patrones de estacionalidad semanal recurrentes.

Este modelo original se utilizó como referencia crítica para validar el valor agregado de la inteligencia artificial. Se determinó que cualquier modelo de *machine learning* propuesto debe superar la precisión de este enfoque heurístico para justificar su puesta en producción.

3.4.2. Implementación del Framework de Modelado

El desarrollo de los modelos avanzados se centralizó en un registro de modelos (*Model registry*) que permitió la orquestación de múltiples algoritmos con hiperparámetros específicos. Para asegurar la robustez de las predicciones, se implementaron las siguientes configuraciones técnicas:

- Modelos lineales y de regularización: se desarrolló un modelo de regresión Ridge con un parámetro de regularización ($\alpha=1,0$) para controlar el posible sobreajuste derivado de la alta dimensionalidad de los datos.
- Ensamblados de árboles: el modelo de Random Forest se configuró con 300 estimadores, mientras que para XGBoost y Catboost se establecieron 500 iteraciones con una tasa de aprendizaje de 0,05. Estos algoritmos se orientaron a capturar las relaciones no lineales entre la inversión publicitaria y el volumen de pedidos.
- Arquitecturas de *Deep Learning*: se desarrollaron redes LSTM para el manejo de dependencias temporales a largo plazo y el modelo *Temporal Fusion Transformer* (TFT), el cual utiliza mecanismos de atención para filtrar variables exógenas que no aportan valor predictivo real.

3.4.3. Estrategia de entrenamiento y mitigación de sobre-ajuste

Para fortalecer la estrategia de entrenamiento y mitigación de sobre-ajuste, se incorporaron técnicas específicas que aseguran la robustez del sistema y su capacidad para operar con datos no vistos. A continuación, se detallan las acciones técnicas implementadas:

- Enfoque de ventana deslizante (en inglés *Sliding Window*): para transformar la serie temporal en un problema de aprendizaje supervisado, se implementó una lógica de ventanas deslizantes. Este método genera pares de características históricas (x) y valores objetivo (y), lo cual permite que modelos como LSTM y TFT capturen las dependencias temporales y secuencias de eventos previos al día de la predicción.
- División cronológica y preservación del orden temporal: a diferencia de otros problemas de *machine learning* donde se aplica un re-ordenamiento aleatorio (en inglés *shuffling*), en este proyecto se evitó esta práctica para mantener la integridad de la secuencia histórica. Dado que el comportamiento de las ventas en Latech presenta dependencias temporales y estacionalidades, preservar el orden de los registros permite que los modelos capturen correctamente la auto-correlación de la serie.
- Simulación de escenario productivo: el conjunto de datos se fragmentó mediante un punto de corte (en el código definido como `split_idx`), que asigna el primer 80 % de los datos al entrenamiento y el 20 % restante a la validación. Al evaluar el rendimiento exclusivamente sobre el segmento de datos más reciente, se garantiza que el modelo sea puesto a prueba frente a un "futuro" que no conoció durante su entrenamiento, lo que permite medir su verdadera capacidad de generalización en un entorno real.
- Mitigación estricta de la fuga de datos (en inglés *data leakage*): esta estrategia asegura que ninguna información proveniente del conjunto de validación influya en el proceso de aprendizaje. Para reforzar este aislamiento,

los parámetros de estandarización técnica (media y desviación estándar) se calcularon únicamente sobre el conjunto de entrenamiento y se aplicaron sobre el conjunto de validación, para evitar así que estadísticas globales del futuro se filtraran en los pesos del modelo.

- Regularización y robustez algorítmica: se seleccionaron arquitecturas con mecanismos internos para combatir el ruido de los datos de Latech. Por ejemplo, se utilizó Random Forest, el cual es intrínsecamente robusto frente a valores atípicos y al sobre-ajuste gracias a su esquema de promediado de múltiples árboles de decisión.
- Evaluación basada en RMSE: se priorizó la métrica RMSE (raíz del error cuadrático medio) en el conjunto de validación para penalizar con mayor rigor los errores de gran magnitud. Esta métrica sirvió como filtro final para asegurar que el modelo ganador no solo tenga un error bajo en promedio, sino que sea confiable en escenarios de alta volatilidad de demanda.

3.5. Desarrollo de un *framework* modular

El diseño del sistema se orientó hacia la creación de una estructura de software modular que permitió la independencia entre los procesos de preparación de datos y las implementaciones de los modelos predictivos. Esta arquitectura se concibió como un entorno extensible, donde la incorporación de nuevas herramientas de inteligencia artificial no requieren alteraciones en el núcleo del *pipeline* de datos.

3.5.1. Estandarización de interfaces y orquestación mediante DAGs

Para garantizar un bajo acoplamiento entre los componentes, se implementaron interfaces estandarizadas que unificaron el comportamiento de todos los modelos integrados. Este enfoque permitió que algoritmos de bibliotecas heterogéneas, tales como: Scikit-learn, XGBoost, Catboost o PyTorch; fueran tratados como objetos intercambiables dentro del flujo de trabajo. El *framework* se organizó en módulos especializados de Python que encapsularon la lógica de entrenamiento, lo cual simplificó la gestión de dependencias y mejoró la legibilidad del código.

La ejecución de estos módulos se coordinó a través de grafos acíclicos dirigidos (DAGs) en Apache Airflow, los cuales orquestaron de manera programada y reproducible cada etapa del *pipeline*, desde la transformación de datos hasta el entrenamiento de modelos. Esta estructura modular facilitó que la lógica de orquestación invocara múltiples arquitecturas de forma paralela, para asegurar que cada tarea se pueda monitorizar y re-ejecutarse ante posibles incidencias técnicas sin afectar el resto del sistema.

3.5.2. Lógica de competencia y selección automática del modelo

Esta organización modular aseguró que el sistema fuera capaz de escalar ante futuras necesidades del negocio. Al definir contratos claros para la entrada y salida de datos, se logró que la lógica de comparación y selección automática funcionara de manera agnóstica a la arquitectura específica de cada modelo.

En la figura 3.2 se puede ver este enfoque competitivo, donde el sistema activa el entrenamiento simultáneo de las diversas arquitecturas registradas y evalúa su

desempeño mediante la métrica RMSE en el conjunto de validación. El flujo identificó y seleccionó de manera autónoma el modelo que presentó el menor error cuadrático medio, que garantiza así que la versión desplegada fuera siempre la que demostrara la mayor precisión y capacidad de generalización. De este modo, el *framework* quedó preparado para integrar nuevos canales de venta o variables exógenas mediante la simple actualización del registro de modelos, con un esfuerzo de desarrollo mínimo y sin comprometer la estabilidad del sistema global.




FIGURA 3.2. Flujo lógico de orquestación de DAGs.

3.6. Despliegue con microservicios e integración con bases de datos

La fase final de la implementación consistió en la orquestación y el despliegue de los módulos desarrollados bajo un esquema de microservicios. Este diseño garantizó que cada componente crítico operara de forma independiente, lo cual facilitó el mantenimiento, el aislamiento de fallos y la escalabilidad selectiva del sistema. La interacción entre estos módulos y el flujo de información desde las fuentes externas hasta la visualización final se detalla en la figura 3.3.




FIGURA 3.3. Diagrama de arquitectura del sistema.

3.6.1. Estrategia de contenerización y orquestación

Se utilizó Docker para definir entornos de ejecución consistentes en todos los servicios del proyecto. Mediante esta herramienta, se generaron contenedores que aseguraron la reproducibilidad y la portabilidad entre las etapas de desarrollo y producción. La coordinación de estos múltiples contenedores se realizó a través de Docker compose, lo cual simplificó la puesta en marcha de la arquitectura de servicios mediante archivos de configuración en formato YAML. Este mecanismo manejó de forma automática las dependencias entre servicios, las redes virtuales y los volúmenes de persistencia necesarios para la estabilidad de la solución.

3.6.2. Arquitectura de microservicios e integración operativa

El sistema se fragmentó en servicios especializados para encapsular las funcionalidades clave definidas en la arquitectura por capas:

- Servicio de ingestión: coordina las tareas programadas (conocidas como `cron`) y los conectores para las APIs externas de Shopify y Triple Whale.
- Servicio de ETL: ejecuta los DAGs de Apache Airflow para la transformación y normalización de los datos crudos.
- Servicio de predicción: opera como el motor de inferencia encargado de consumir el modelo ganador almacenado en el registro de modelos.
- API interna para Inventory Tracker: expone los resultados de las predicciones para su consumo final.

La comunicación entre estos componentes se realizó mediante endpoints REST internos para operaciones síncronas. Para los procesos que requirieron un procesamiento asíncrono, se implementaron colas de mensajería (Redis), lo cual aseguró un bajo acoplamiento entre las partes.

3.6.3. Integración con la capa de persistencia y servicios externos

La base de datos PostgreSQL funcionó como el núcleo de almacenamiento estructurado para los datos consolidados. Esta integración permitió que el sistema mantuviera su autonomía ante interrupciones en las APIs externas y optimizó la velocidad de consulta durante el entrenamiento de los modelos. Los microservicios interactuaron con las tablas `orders` y `forecast` de manera acotada, lo cual protegió la integridad del esquema de datos diseñado. Para la entrega de pronósticos, se utilizó el framework FastAPI, el cual destacó por su arquitectura asíncrona de alto rendimiento y su capacidad de validación automática de datos mediante Pydantic. Este servicio proporcionó la documentación técnica necesaria para que el sistema Inventory Tracker consultara las estimaciones de ventas en tiempo real, de modo que se integraron las proyecciones con los datos operativos del cliente.

A continuación, se detallan los aspectos clave de esta integración:

- Autonomía y resiliencia de datos: el almacenamiento local en PostgreSQL actuó como una capa de abstracción que protegió al sistema frente a caídas temporales, límites de tasa (`rate limits`) o cambios estructurales en las APIs de Shopify y Triple Whale. Esta copia local garantizó la disponibilidad

continúa del servicio de predicción independientemente del estado de los servicios externos.

- **Persistencia de datos enriquecidos:** la base de datos no solo almacenó registros crudos, sino que albergó información procesada y enriquecida con variables críticas para el negocio, tales como la distinción entre clientes nuevos y recurrentes, el cálculo de semanas desde la primera compra (`diff_weeks_from_first_purchase`) y la identificación de días de la semana o meses para capturar la estacionalidad.
- **Gestión de artefactos y modelos (AWS S3):** para complementar a PostgreSQL, se integró AWS S3 para el almacenamiento de objetos de gran tamaño, tales como los modelos serializados, archivos de configuración y datos intermedios en formato Parquet. Esta infraestructura aseguró la durabilidad y escalabilidad necesaria para manejar el historial creciente de experimentos y versiones de modelos.
- **Validación de datos con Pydantic:** el uso de FastAPI permitió implementar esquemas de datos estrictos mediante Pydantic. Esto aseguró que cualquier consulta realizada desde Inventory Tracker cumpliera con los tipos de datos esperados (fechas, magnitudes de ventas), lo cual redujo errores de comunicación entre el *frontend* y el motor de inteligencia artificial.
- **Documentación técnica automatizada:** la integración con FastAPI generó automáticamente documentación interactiva bajo el estándar Open API (con Swagger). Esta herramienta facilitó las pruebas de integración para los desarrolladores de Latech y permitió probar los endpoints de predicción y refresco de datos de forma aislada y documentada.
- **Seguridad y trazabilidad:** la capa de persistencia incluyó mecanismos de auditoría mediante *logs* de ejecución, la fecha de la última predicción generada y cualquier incidencia detectada durante la ingesta o el entrenamiento. Además, se contempló la anonimización de datos sensibles para cumplir con la ley de protección de datos personales.

Capítulo 4

Ensayos y resultados

Este capítulo detalla el conjunto de pruebas experimentales diseñadas para validar la propuesta técnica. Se exponen los resultados cuantitativos obtenidos y se desarrolla un análisis crítico para verificar el cumplimiento de los objetivos establecidos.

4.1. Ensayos de modelos

Para garantizar una comparación equitativa entre las arquitecturas, se realizó una búsqueda en rejilla (en inglés *grid search*) sobre cada modelo del registro. Este proceso permitió explorar diferentes combinaciones de hiperparámetros, tales: como el número de estimadores, la profundidad máxima de los árboles y la tasa de aprendizaje en algoritmos de boosting. A través de esta técnica, se buscó que el desempeño reportado se aproximara a la capacidad óptima de cada arquitectura dentro del espacio de búsqueda definido.

A continuación, se describen las configuraciones finales de los modelos evaluados:

- Lineal regression y Ridge: se implementó como modelos base para establecer relaciones lineales entre las variables. En el caso de Ridge, se aplicó un parámetro de regularización $\alpha=5$ para mitigar la complejidad del modelo y controlar el riesgo de sobreajuste.
- Random forest: este algoritmo de ensamble se seleccionó por su robustez intrínseca ante valores atípicos y su capacidad para promediar múltiples árboles de decisión. Su configuración óptima consistió en 100 estimadores, una profundidad máxima de 8, un mínimo de 2 muestras para división y 3 muestras por hoja.
- XGBoost: este modelo de gradient boosting permite optimizar la precisión de manera iterativa sin memorizar el ruido histórico. Los hiperparámetros finales incluyeron 400 estimadores, una profundidad de 4, una tasa de aprendizaje (*learning rate*) de 0,05 y un submuestreo de filas del 90 %.
- CatBoost: se utilizó esta variante de boosting por su eficiencia en el manejo de variables categóricas y su función de pérdida orientada a minimizar el RMSE. Se configuró con 500 iteraciones, una tasa de aprendizaje de 0,1 y una profundidad de 4.

- Modelos estadísticos clásicos (SARIMA y *Exponential smoothing*): estos métodos se aplicaron para modelar los componentes de tendencia y estacionalidad predominantes en la serie. Para SARIMA, se definieron los parámetros de orden (3,1,2) y un componente estacional de (0,1,1) con un periodo de 12 meses.
- NeuralProphet: este modelo combina la flexibilidad de las redes neuronales con el modelado aditivo de tendencias y días festivos. La configuración ganadora utilizó 40 épocas de entrenamiento y una tasa de aprendizaje de 0,05.
- LSTM (*Long short-term memory*): esta red neuronal recurrente se diseñó para retener información relevante a largo plazo y capturar dependencias temporales complejas. El modelo final integró 3 capas, un tamaño de capa oculta de 256, un dropout de 0,05 para regularización y un entrenamiento de 50 épocas con un tamaño de lote de 128.
- Temporal fusion transformer (TFT): esta arquitectura de vanguardia emplea mecanismos de atención interpretable para filtrar variables exógenas, como la inversión publicitaria, que no aportan valor predictivo real. Su configuración incluyó un largo de codificador de 28 días, 10 épocas, un tamaño de lote de 32 y una tasa de aprendizaje de 0,01.

4.2. Desempeño de los modelos

Una vez finalizada la fase de ensayos, se evaluó cada arquitectura sobre el conjunto de validación donde se utilizó un enfoque de división cronológica. Esta metodología permitió medir la capacidad de generalización de los modelos frente a datos no vistos, siempre se preservó la integridad de la secuencia temporal de las ventas de Latech.

A continuación, la tabla 4.1 resume el rendimiento alcanzado por cada modelo en términos de MAE (error absoluto medio), RMSE (raíz del error cuadrático medio) y MAPE (error porcentual absoluto medio).

TABLA 4.1. Comparativa de métricas de desempeño por modelo

Modelo	MAE	RMSE	MAPE
TFT	258,68	443,67	0,128
NeuralProphet	356,68	568,48	0,191
CatBoost	349,70	549,54	0,392
XGBoost	367,31	553,82	0,400
LSTM	376,89	576,42	0,359
SARIMA	380,89	583,75	0,221
Random Forest	375,39	589,93	0,389
Ridge	521,10	728,93	0,632
Linear Reg.	549,94	761,11	0,614
Exp. Smoothing	593,54	701,40	0,392

El análisis cuantitativo permite extraer las siguientes conclusiones sobre el comportamiento de las arquitecturas:

- Superioridad de modelos de vanguardia: el modelo TFT presentó el mejor desempeño global, con un RMSE de 443,67 y el MAPE más bajo del conjunto (12,8 %). Estos resultados validan la capacidad de sus mecanismos de atención para filtrar variables exógenas y capturar la complejidad de la demanda de Latech.
- Captura de estacionalidad: modelos como NeuralProphet y SARIMA demostraron una notable precisión en términos de MAPE (19,1 % y 22,1 % respectivamente). Esto indica que la lógica de componentes estacionales y de tendencia de estas arquitecturas logra modelar adecuadamente los ciclos de venta mensuales y semanales de la empresa.
- Limitaciones de modelos lineales: las arquitecturas lineales y de suavizado (Ridge, Regresión lineal y Exponential smoothing) exhibieron los errores más elevados. La disparidad en el RMSE, que alcanzó valores superiores a 700, sugiere que estos métodos no logran procesar de forma eficiente las relaciones no lineales provocadas por picos de campañas publicitarias o eventos exógenos.
- Modelos de ensamble: tanto CatBoost como XGBoost mantuvieron una consistencia sólida con RMSEs cercanos a 550. Su robustez intrínseca permitió generalizar las relaciones entre la inversión publicitaria consolidada y el volumen de pedidos, lo cual mitiga el riesgo de sobreajuste detectado en las fases iniciales del proyecto.

4.3. Desempeño de la predicción

El rendimiento superior de los modelos de aprendizaje profundo en este estudio se debe a su capacidad para procesar una serie temporal caracterizada por una alta volatilidad y dependencias no lineales complejas. A diferencia de los métodos estadísticos tradicionales, estas arquitecturas logran integrar variables exógenas y capturar cambios estructurales en los datos de manera dinámica.




FIGURA 4.1. Distribución de las ordenes.

Como se observa en la Figura 4.1, la demanda presenta tres componentes críticos que justifican el uso de modelos avanzados:

- Impacto de eventos estocásticos: la presencia de líneas punteadas rojas en el gráfico indica el inicio de eventos clave como ofertas, días feriados o lanzamientos de productos. Existe una correlación visual directa entre estos hitos y el incremento súbito en la cantidad de órdenes por día.
- Volatilidad y variabilidad: las órdenes muestran una oscilación constante y agresiva, lo que sugiere que factores externos y estacionalidades de corto plazo influyen fuertemente en el comportamiento diario.
- Tendencia ascendente longitudinal: a medida que transcurre el tiempo (desde 2023 hasta la actualidad), se aprecia una clara tendencia al aumento en el volumen base de órdenes.

Para profundizar en el análisis del comportamiento de las arquitecturas Temporal fusion transformer y NeuralProphet, seleccionadas por su desempeño superior en las fases de ensayo previas. El enfoque se centra en validar la estabilidad de sus predicciones y su capacidad para replicar la dinámica real de las ventas de Latech. Se plantea examinar la distribución de los RMSE:




FIGURA 4.2. RMSE Neural prophet.

En las figuras 4.2 y 4.3 se ilustran la distribución del RMSE para ambos algoritmos. Estos gráficos permiten verificar la consistencia de los modelos y la concentración del error en rangos reducidos, lo que demuestra la robustez de ambas soluciones ante la volatilidad de la demanda histórica.

La baja dispersión del error en estas arquitecturas confirma que el sistema mantiene una precisión estable, un factor crítico para la confiabilidad de los pronósticos de inventario.

4.3.1. Precisión general y sesgo

- TFT: muestra una mayor concentración de errores cerca del cero, con una frecuencia máxima que supera los 300 casos en el primer *bin*. Este fenómeno




FIGURA 4.3. RMSE TFT.

es atribuible a la falta de profundidad histórica en las primeras observaciones, lo que limita la capacidad de los modelos para establecer una ventana de contexto adecuada y capturar la inercia de la demanda de manera efectiva. A su vez, esto indica que para la gran mayoría de las predicciones, el error es significativamente bajo.

- NeuralProphet: aunque también concentra la mayoría de sus errores en el rango inicial, su frecuencia máxima es menor (alrededor de 210). Este modelo comete errores de mayor magnitud de forma más frecuente. Esto sugiere que el TFT es, en promedio, más preciso y consistente en sus predicciones.

4.3.2. Análisis de outliers


Ambas representaciones gráficas exhiben una asimetría positiva pronunciada, lo que significa que ambos modelos sufren ante eventos atípicos o picos de demanda difíciles de predecir. Sin embargo:

- TFT: la curva de densidad decae mucho más rápido. Después del primer bloque de error, la frecuencia cae casi a cero de forma inmediata.
- NeuralProphet: muestra pequeñas zonas de errores más alejadas (cerca de $1,5 \times 10^6$ y $3,0 \times 10^6$). Esto indica que NeuralProphet comete errores medianos y grandes con mayor frecuencia que el TFT.

4.3.3. Estabilidad y Confiabilidad

El modelo TFT demuestra ser más robusto para este conjunto de datos. Su distribución es más estrecha y alta, lo que indica una menor varianza en el error. Esto coincide con los resultados de la tabla comparativa, donde el TFT obtuvo un RMSE de 443,67 frente al 568,48 de NeuralProphet.

A continuación, se realiza un análisis de la distribución del RMSE del modelo *baseline* en la figura 4.4

FIGURA 4.4. RMSE *Baseline*.

Al contrastar la distribución del error cuadrático del modelo TFT frente al *Baseline*, se evidencia una diferencia sustancial en la consistencia de las predicciones. Mientras que el modelo TFT logra concentrar la gran mayoría de sus residuos en el rango cercano a cero (con una frecuencia superior a los 300 casos), el *Baseline* muestra una dispersión significativamente mayor. Este último no solo presenta una menor frecuencia de aciertos precisos, sino que manifiesta errores en magnitudes mucho más elevadas, visibles en la asimetría positiva de la derecha de la distribución.

4.4. Comparación de algoritmos

Para complementar el análisis, se integran visualizaciones que contrastan los valores históricos reales con las proyecciones generadas por cada modelo entrenado. Para entender los gráficos que se presentan a continuación se explica cada eje de coordenadas:

- Eje horizontal: si hay fechas válidas, representa días transcurridos desde la primera fecha del tramo de validación. Cada punto consecutivo es un día (u orden temporal) del subconjunto de validación.
- Eje vertical: magnitud del *target* (*values* en el gráfico), en la misma escala para ambas curvas: línea *True* (y_{true}) y línea *Prediction* (y_{pred}).

4.4.1. Predicciones de Neural prophet

La Figura 4.5 expone el desempeño de NeuralProphet, cuya estructura permite modelar de forma precisa los ciclos de estacionalidad mensual y semanal característicos de la tienda. Estas comparativas visuales aseguran que el modelo seleccionado mantenga una estrecha correlación con la dinámica del negocio antes de su integración final en la plataforma Inventory Tracker.




FIGURA 4.5. Comparativa de predicciones vs. valores reales: Mezcla lineal frente a Baseline.

4.4.2. Predicciones de TFT

La Figura 4.6 muestra el gráfico de realidad en comparación con la predicción del modelo TFT. En esta representación se observa la capacidad de sus mecanismos de atención para capturar los picos de demanda asociados a los periodos de mayor inversión publicitaria.




FIGURA 4.6. Comparativa de predicciones vs. valores reales: Mezcla lineal frente a TFT.

SSS S S S S SS




FIGURA 4.7. Comparativa de predicciones vs. valores reales: Mezcla lineal frente a Baseline.

TABLA 4.2. Comparativa de métricas de desempeño por modelo

Modelo	MAE	RMSE	MAPE
TFT	258,68	443,67	0,128
Baseline	338,04	548,02	0,18

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Resultados obtenidos

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Trabajo futuro

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] *LaTechFactory*. <https://latechfactory.com/>. Accedido: 2025-11-23.
- [2] *TikTok for Business*. <https://business.tiktok.com/en/>. Accedido: 2025-11-23.
- [3] *Instagram for Business*. <https://business.instagram.com/>. Accedido: 2025-11-23.
- [4] *Facebook for Business*. <https://business.facebook.com/>. Accedido: 2025-11-23.
- [5] *Google Ads*. <https://ads.google.com/>. Accedido: 2025-11-23.
- [6] *Triple Whale API*. <https://triplewhale.com/api>. Accedido: 2025-11-09.
- [7] *Shopify API*. <https://shopify.dev/api>. Accedido: 2025-11-09.
- [8] George E. P. Box et al. *Time Series Analysis: Forecasting and Control*. 5th. Wiley, 2015.
- [9] Rob J Hyndman y George Athanasopoulos. *Forecasting: principles and practice*. 2nd. OTexts, 2018. URL: <https://otexts.com/fpp3/>.
- [10] Sepp Hochreiter y Jürgen Schmidhuber. «Long short-term memory». En: *Neural Computation*. Vol. 9. 8. MIT Press, 1997, págs. 1735-1780.
- [11] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [12] Leo Breiman. «Random forests». En: *Machine Learning* 45.1 (2001), págs. 5-32.
- [13] Kasun Bandara, Christoph Bergmeir y Slawek Smyl. «Forecasting sales with machine learning in e-commerce». En: *International Journal of Forecasting* (2020).
- [14] Bryan Lim et al. «Temporal Fusion Transformers for interpretable multi-horizon time series forecasting». En: *International Journal of Forecasting* 37.4 (2021), págs. 1748-1764. URL: <https://www.sciencedirect.com/science/article/pii/S0169207021000637>.
- [15] Haoyi Zhou et al. «Informer: Beyond efficient transformer for long sequence time-series forecasting». En: *Proceedings of the AAAI Conference on Artificial Intelligence* 35.12 (2021), págs. 11106-11115.
- [16] Boris N Oreshkin et al. «N-BEATS: Neural basis expansion analysis for interpretable time series forecasting». En: *arXiv preprint arXiv:1905.10437* (2019).
- [17] Spyros Makridakis, Evangelos Spiliotis y Vassilios Assimakopoulos. «The M5 competition: Background, organization, and implementation». En: *International Journal of Forecasting* 36.4 (2020), págs. 1451-1457.
- [18] *Amazon Forecast*. <https://aws.amazon.com/forecast/>. Accedido: 2025-11-09.
- [19] *Amazon Web Services (AWS)*. <https://aws.amazon.com/>. Accedido: 2025-11-09.
- [20] Sean J Taylor y Ben Letham. *Forecasting at scale*. Vol. 72. 1. Taylor & Francis, 2018, págs. 37-45.
- [21] *Meta for Developers*. <https://developers.facebook.com/>. Accedido: 2025-11-09.

- [22] *RandomForestRegressor* — *scikit-learn documentation*. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>. Accedido: 2025-11-23.
- [23] Jerome H. Friedman. *Greedy Function Approximation: A Gradient Boosting Machine*. <https://jerryfriedman.su.domains/ftp/trebst.pdf>. Accedido: 2025-11-23. 2001. DOI: [10.1214/aos/1013203451](https://doi.org/10.1214/aos/1013203451).
- [24] Rob J. Hyndman et al. *Forecasting with Exponential Smoothing: The State Space Approach*. Accedido: 2025-11-23. 2008. URL: https://www.academia.edu/76833440/Forecasting_with_Exponential_Smoothing_The_State_Space_Approach_by_Rob_J_Hyndman_Anne_B_Koehler_J_Keith_Ord_Ralph_D_Snyder.
- [25] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation». En: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Accedido: 2025-11-23. ACL. 2014, págs. 1724-1734. URL: <https://arxiv.org/abs/1406.1078>.
- [26] Jeff Reback et al. «pandas: powerful Python data analysis toolkit». En: *Zenodo* (2020). DOI: [10.5281/zenodo.3509134](https://doi.org/10.5281/zenodo.3509134). URL: <https://pandas.pydata.org/>.
- [27] Charles R. Harris et al. «Array programming with NumPy». En: *Nature* 585.7825 (2020), págs. 357-362. DOI: [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2). URL: <https://numpy.org/doc/stable/>.
- [28] Fabian Pedregosa et al. «Scikit-learn: Machine learning in Python». En: *Journal of Machine Learning Research* 12 (2011), págs. 2825-2830. URL: <https://scikit-learn.org/stable/>.
- [29] Adam Paszke, Sam Gross, Francisco Massa et al. *PyTorch: An Open Source Machine Learning Framework*. <https://pytorch.org/>. Accedido: 2025-02-13. PyTorch Foundation, 2025.
- [30] John D. Hunter. *Matplotlib: A 2D graphics environment*. Vol. 9. 3. IEEE, 2007, págs. 90-95. URL: <https://matplotlib.org/>.
- [31] Michael L. Waskom. «Seaborn: statistical data visualization». En: *Journal of Open Source Software* 6.60 (2021), pág. 3021. DOI: [10.21105/joss.03021](https://doi.org/10.21105/joss.03021). URL: <https://seaborn.pydata.org/>.
- [32] Plotly Technologies Inc. *Plotly Python Open Source Graphing Library*. <https://plotly.com/python/>. Accedido: 2025-11-23. 2015.
- [33] The PostgreSQL Global Development Group. *PostgreSQL Documentation*. <https://www.postgresql.org/docs/current/>. Consultado: 9 de mayo de 2026. 2024.
- [34] *Cron Manual*. <https://man7.org/linux/man-pages/man5/crontab.5.html>. Accedido: 2025-02-13.
- [35] *Amazon Simple Storage Service (S3) Documentation*. Accedido: 2025-02-13. Amazon Web Services. 2025.
- [36] Scott Chacon y Ben Straub. *Pro Git*. 2.^a ed. Accedido: 2025-02-13. Apress, 2014. URL: <https://git-scm.com/book/en/v2>.
- [37] ASGI Community. *ASGI: Asynchronous Server Gateway Interface*. <https://asgi.readthedocs.io/en/latest/>. Acceso: 2025-11-27. 2024.
- [38] Pydantic Team. *Pydantic Documentation*. <https://docs.pydantic.dev/latest/>. Acceso: 2025-11-27. 2024.
- [39] Swagger API. *Swagger: API Design Tools and Documentation*. <https://swagger.io/>. Acceso: 2025-11-27. 2024.
- [40] Docker, Inc. *Docker Documentation*. <https://docs.docker.com/>. Acceso: 2025-11-27. 2024.

- [41] *Docker Compose Documentation*. <https://docs.docker.com/compose/>. Accedido: 2025-02-13. Docker, Inc., 2025.
- [42] Metaflow Team, Netflix. *Metaflow: Human-Centric Framework for Data Science*. <https://docs.metaflow.org/>. Acceso: 2025-11-27. 2024.
- [43] Apache Software Foundation. *Apache Airflow Documentation*. <https://airflow.apache.org/docs/>. Acceso: 2025-11-27. 2024.
- [44] *Directed Acyclic Graphs (DAGs) in Apache Airflow*. <https://airflow.apache.org/docs/apache-airflow/stable/core-concepts/dags.html>. Accedido: 2025-11-27.
- [45] *¿Qué es el proceso ETL?* <https://azure.microsoft.com/es-es/resources/cloud-computing-dictionary/what-is-etl/>. Consultado: 9 de mayo de 2026.
- [46] Technical Team. *REST API Documentation*. Disponible en <https://swagger.io/specification/>. Swagger API. 2026.
- [47] *RabbitMQ: Messaging that just works*. <https://www.rabbitmq.com/>. Accedido: 2025-12-02.
- [48] *Redis: In-memory data structure store*. <https://redis.io/>. Accedido: 2025-12-02.