

Pronóstico de ventas para toma de decisiones en comercio electrónico usando *Machine Learning*

Ing. Jonathan Matias Borda

Carrera de Especialización en Inteligencia Artificial

Director: Dr. Diego Onna (Universidad de Buenos Aires)

Jurados:

Jurado 1 (pertenencia)
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

Ciudad de Buenos Aires, junio de 2026

Resumen

En la presente memoria se describe el desarrollo de un modelo de inteligencia artificial para el pronóstico de ventas en la tienda en línea de la empresa Latech, dedicada a la producción y comercialización de barritas alimenticias. El trabajo tiene como finalidad mejorar la planificación de la producción y facilitar la gestión del inventario y toma de decisiones estratégicas en la empresa.

Para su realización se aplicaron conocimientos de análisis de datos, modelado de series temporales, aprendizaje automático, integración de APIs y desarrollo de software.

Índice general

Resumen	I
1. Introducción general	1
1.1. Contexto y motivación	1
1.2. Estado del arte	2
1.3. Objetivo y alcance	3
1.3.1. Objetivo del trabajo	3
1.3.2. Alcance del trabajo	3
2. Introducción específica	5
2.1. Requerimientos	5
2.2. Modelos de inteligencia artificial utilizados	6
2.3. Tratamiento de datos (herramientas)	7
3. Diseño e implementación	9
3.1. Arquitectura del sistema	9
3.1.1. Capa de recolección de datos	10
3.1.2. Capa de procesamiento y transformación	10
3.1.3. Capa de almacenamiento estructurado	10
3.1.4. Capa de modelado predictivo	12
3.1.5. Integración operativa con microservicios	12
3.1.6. Integración en Inventory Tracker	13
3.1.7. Justificación global de la arquitectura	13
3.1.8. Capa de adquisición	13
3.1.9. Capa de procesamiento y generación del dataset final	13
3.1.10. Base de datos unificada	15
3.1.11. Condiciones del trabajo	15
3.2. Análisis de datos	15
3.3. Desarrollo de modelos	15
3.4. Desarrollo de un framework modular	15
3.5. Despliegue con microservicios e integración con bases de datos	15
4. Ensayos y resultados	17
4.1. Ensayos de modelos	17
4.2. Desempeño del modelo	17
4.3. Desempeño de la predicción	17
4.4. Comparación de algoritmos	17
4.5. Validación de cumplimiento de requerimientos	17
Requerimiento funcional 1	17
Requerimiento funcional 2	18
Requerimiento funcional 3	18
Requerimiento funcional 4	19
Requerimiento funcional 5	19

Requerimiento funcional 6	20
Requerimiento funcional 7	20
5. Conclusiones	23
5.1. Resultados obtenidos	23
5.2. Trabajo futuro	23
Bibliografía	25

Índice de figuras

1.1. Flujo general del sistema para generar el pronóstico de ventas. . . .	1
3.1. Diagrama Entidad-Relación. Muestra las dos tablas principales. . .	11

Índice de tablas

Capítulo 1

Introducción general

En este capítulo se presenta el contexto general del trabajo y la problemática que motivó su desarrollo. Se exponen las razones y necesidades que impulsaron su realización, junto con una descripción de las soluciones existentes y los enfoques actuales relacionados con la temática abordada. Asimismo, se detallan los propósitos principales del trabajo y se delimitan los alcances y límites de su implementación.

1.1. Contexto y motivación

El presente trabajo forma parte de la Carrera de Especialización en Inteligencia Artificial y tiene como propósito el desarrollo de un modelo capaz de pronosticar las ventas de una tienda en línea perteneciente a la empresa Latech. La empresa fabrica y comercializa barritas alimenticias en distintos sabores, lo que requiere una planificación de producción precisa para evitar tanto faltantes como excedentes de stock. En este contexto, contar con pronósticos confiables de ventas constituye un factor estratégico clave para la toma de decisiones operativas y comerciales.

La ausencia de un sistema de pronóstico confiable generaba dificultades en la planificación estratégica y operativa de la empresa. En particular, cuando una campaña de marketing resultaba exitosa y aumentaban significativamente las visitas y las compras, la capacidad de producción no siempre lograba adaptarse con la suficiente rapidez, lo que en ocasiones derivaba en falta de stock. Esta situación ya se había presentado previamente y había generado retrasos en la entrega de pedidos y afectado la experiencia del cliente.

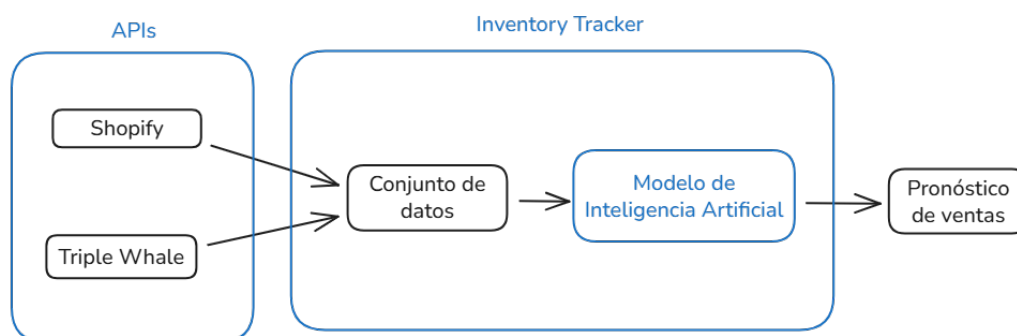


FIGURA 1.1. Flujo general del sistema para generar el pronóstico de ventas.

La integración de las APIs permite centralizar información obtenida desde diversos canales de difusión. Entre ellas se encuentran TikTok, Instagram, Facebook y Google. Esta diversidad de fuentes permite identificar qué plataformas participan en el proceso de conversión y servirá como base para estimar aspectos como la proporción de usuarios nuevos y recurrentes, así como las variaciones en el volumen de ventas según el canal. Además, en el sitio de ventas los usuarios pueden suscribirse a compras mensuales, lo que permite analizar la actividad de las suscripciones: identificar cuándo los usuarios mantienen sus suscripciones activas y cuándo las cancelan. Esta información adicional resulta valiosa para comprender patrones de compra recurrentes y estimar la demanda futura de manera más precisa.

La incorporación conjunta de datos históricos de ventas (Shopify) y de inversión publicitaria (Triple Whale) proporciona un insumo clave para el entrenamiento del modelo de predicción de ventas. Contar con estas dos fuentes permite relacionar la inversión realizada en cada plataforma con los resultados obtenidos en términos de ventas, lo que contribuye a la construcción de un modelo más preciso y contextualizado.

De este modo, el trabajo apunta a desarrollar un sistema que utilice aprendizaje automático como herramienta de apoyo a la planificación comercial y a la toma de decisiones basadas en datos.

1.2. Estado del arte

En la actualidad, el pronóstico de ventas mediante técnicas de inteligencia artificial constituye un área de creciente interés en el ámbito del comercio electrónico. Los avances en el análisis de datos y en el aprendizaje automático han permitido el desarrollo de modelos capaces de anticipar la demanda con altos niveles de precisión. Esto contribuye a una mejor planificación de la producción, la gestión de inventarios y la toma de decisiones estratégicas.

Entre los enfoques más utilizados se encuentran los modelos de series temporales clásicos, como ARIMA [1], SARIMA y *Exponential Smoothing*, que permiten capturar patrones estacionales y tendencias a lo largo del tiempo [2]. Sin embargo, estos métodos suelen presentar limitaciones cuando los datos incluyen múltiples factores externos, como campañas publicitarias, canales de venta o comportamiento del usuario.

En respuesta a esas limitaciones, en los últimos años se ha incrementado el uso de técnicas de aprendizaje profundo (*Deep Learning*) y aprendizaje automático (*Machine Learning*), que ofrecen una mayor capacidad para modelar relaciones no lineales y para integrar múltiples fuentes de información. Modelos como Redes Neuronales Recurrentes (RNN), LSTM (*Long Short-Term Memory*) y *Random Forest Regressor* se han aplicado con éxito en la predicción de ventas en entornos de comercio electrónico, debido a su habilidad para capturar dependencias temporales y correlaciones entre variables [3, 4, 5, 6].

Asimismo, el uso de plataformas integradas de datos, tales como Shopify [7] y Triple Whale [8], ha impulsado el desarrollo de soluciones personalizadas que combinan información transaccional, métricas de marketing y comportamiento de los usuarios. Estas herramientas permiten no solo mejorar la precisión de los

modelos de pronóstico, sino también ofrecer una visión integral del desempeño comercial y de la efectividad de las campañas publicitarias.

Entre las soluciones comerciales más reconocidas se destacan Amazon Forecast [9], un servicio basado en redes neuronales desarrollado por Amazon Web Services [10] que automatiza la creación de modelos de predicción de demanda, y Prophet [11], una herramienta de código abierto creada por Meta (Facebook) [12] que utiliza un enfoque aditivo para modelar tendencias y estacionalidades de manera flexible. Ambas herramientas representan referencias relevantes en el campo del pronóstico de series temporales con datos de negocios.

La tendencia actual en el campo apunta hacia el desarrollo de modelos híbridos, que combinan la capacidad de las redes neuronales para capturar relaciones no lineales y complejas con la robustez e interpretabilidad de las técnicas tradicionales (como ARIMA o SARIMA). Esta combinación permite alcanzar una mayor precisión y robustez en los pronósticos. El sector minorista ha sido el principal adoptante de estos enfoques, ya que sus ventas están muy influenciadas por factores externos como la publicidad digital, las promociones y la estacionalidad.

En este marco, el trabajo desarrollado se apoyó en los enfoques actuales de predicción de demanda mediante aprendizaje automático, datos históricos de ventas, inversión publicitaria y comportamiento del usuario. El objetivo fue construir un modelo que reflejara las tendencias reales del negocio y sirviera como herramienta de apoyo para la toma de decisiones estratégicas en la empresa Latech.

1.3. Objetivo y alcance

En esta sección se mencionan los propósitos principales del trabajo y los límites de su implementación.

1.3.1. Objetivo del trabajo

El propósito de este trabajo es desarrollar un modelo de inteligencia artificial que permita predecir con precisión las ventas del producto alimenticio de la empresa Latech, a partir de datos de ventas y de inversión publicitaria. Esto permitirá a la empresa: anticipar sus necesidades de producción, optimizar la planificación del inventario y tomar decisiones estratégicas basadas en datos. Asimismo, podrá reducir el riesgo de faltantes o excesos de inventario, y mejorar la eficiencia operativa y comercial.

1.3.2. Alcance del trabajo

A continuación, se enuncian los items que incluye el trabajo:

- Relevamiento y análisis de los datos históricos de ventas de la tienda en línea obtenidos mediante la API de Shopify.
- Relevamiento y análisis de los datos históricos de inversión publicitaria provenientes de la API de Triple Whale.
- Limpieza, transformación y consolidación de datos provenientes de ambas plataformas.

- Análisis exploratorio de datos (EDA) para identificar patrones, tendencias y relaciones entre las variables.
- Desarrollo y entrenamiento de modelos de inteligencia artificial orientados a la predicción de ventas.
- Evaluación comparativa de distintos modelos para seleccionar el que ofrezca la mejor precisión y capacidad predictiva.
- Implementación de un módulo funcional integrado al sistema Inventory Tracker de la empresa, que permita realizar predicciones de ventas para períodos futuros.
- Documentación técnica del proceso, del modelo elegido y de su uso.
- Entrega de reportes que expliquen los hallazgos y recomendaciones derivadas del análisis.

Por otra parte, quedan excluidas del alcance las siguientes actividades:

- Implementaciones en tiempo real del modelo, es decir, sistemas que actualicen las predicciones de forma instantánea ante cada nuevo dato recibido. Sí se contempla la posibilidad de programar ejecuciones periódicas del modelo (por ejemplo, una vez al día) para actualizar las predicciones de manera regular.
- Garantía de precisión absoluta en las predicciones, ya que la precisión depende de la calidad y estabilidad de los datos futuros y de factores externos no controlables.
- Acciones o recomendaciones específicas sobre estrategias de marketing más allá de lo inferido de los análisis de datos.
- Optimización de procesos internos de producción o logística, salvo en lo que respecta a la estimación de demanda.

Capítulo 2

Introducción específica

En este capítulo se presentan los requerimientos más importantes, los modelos de inteligencia artificial utilizados y las herramientas usadas para el tratamiento de datos.

2.1. Requerimientos

En esta sección se presentan algunos requerimientos establecidos para el trabajo. En cada requerimiento se detalla su objetivo y alcance, con el fin de precisar las condiciones necesarias para el desarrollo y la correcta implementación del modelo propuesto.

- Importación de datos de ventas desde Shopify: el sistema debe permitir la obtención de datos históricos y actualizados de ventas desde la plataforma Shopify, con el objetivo de utilizarlos en el proceso de entrenamiento del modelo de predicción de demanda.
- Importación de datos de inversión publicitaria desde Triple Whale: el sistema debe permitir la incorporación de datos de inversión publicitaria provenientes de la plataforma Triple Whale, con el propósito de integrar esta variable en el análisis y modelado de ventas.
- Consolidación de datos provenientes de Shopify y Triple Whale: el sistema debe unificar la información de ventas y de inversión publicitaria en un único conjunto de datos, con el fin de preparar una base consistente para el entrenamiento del modelo de predicción.
- Entrenamiento del modelo de predicción de ventas: el objetivo de este requerimiento fue desarrollar y entrenar un modelo de predicción que permita anticipar el comportamiento de las ventas futuras utilizando como base el *dataset* consolidado.
- Visualización de predicciones de ventas en Inventory Tracker: el objetivo de este requerimiento fue permitir a los usuarios de Inventory Tracker consultar y analizar las predicciones de ventas generadas por el modelo, integrándolas con los datos históricos disponibles para facilitar la planificación de la producción.
- Descarga de predicciones de ventas en formato CSV: el objetivo de este requerimiento fue permitir a los usuarios de Inventory Tracker exportar las predicciones de ventas a un archivo CSV para su análisis externo o integración con otras herramientas de planificación.

2.2. Modelos de inteligencia artificial utilizados

Para abordar el trabajo se evaluaron y aplicaron diversos modelos de inteligencia artificial, dado que el comportamiento de la demanda no responde a un único patrón fijo ni puede ser capturado adecuadamente por un solo tipo de modelo. También, se consideró seleccionar aquel que ofreciera el mejor equilibrio entre precisión, interpretabilidad y capacidad de generalización.

A continuación, se describen los tipos de modelos aplicados:

- *Random Forest Regressor* [13]: se utilizó por su robustez frente a sobreajuste y su capacidad para capturar relaciones no lineales entre variables. Este modelo resulta especialmente útil cuando se integran múltiples fuentes de datos, como ventas históricas e inversión publicitaria.
- *Gradient Boosting Machines* [14] (XGBoost, LightGBM): se evaluaron por su alto rendimiento en competencias de ciencia de datos y su eficiencia computacional. Estos modelos permiten optimizar la función de pérdida de manera iterativa, mejorando la precisión en la predicción de series temporales con características externas.
- *SARIMA (Seasonal Autoregressive Integrated Moving Average)*: se aplicó para modelar la estacionalidad y tendencia presentes en los datos de ventas. SARIMA es especialmente efectivo cuando el comportamiento temporal es predominante y estable a lo largo del tiempo.
- *Exponential Smoothing (ETS)* [15]: se consideró como alternativa para capturar patrones estacionales y de tendencia con un enfoque más intuitivo y menos paramétrico que SARIMA.
- *Long Short-Term Memory (LSTM)*: se implementaron redes LSTM debido a su habilidad para retener información a largo plazo y modelar dependencias temporales complejas. Este tipo de red es adecuado para series temporales con patrones no lineales y múltiples variables exógenas, como la inversión publicitaria por plataforma.
- *GRU (Gated Recurrent Unit)* [16]: se evaluó como una variante más simple y computacionalmente eficiente de las LSTM, útil cuando los recursos de entrenamiento son limitados.
- *Enfoque híbrido*: se exploró la combinación de modelos clásicos (como SARIMA) con redes neuronales (como LSTM), con el fin de aprovechar la capacidad de los primeros para modelar componentes estacionales y de tendencia, y la flexibilidad de las segundas para capturar relaciones no lineales y efectos de variables externas.
- *Prophet*: se incluyó el modelo Prophet, desarrollado por Meta [12], por su facilidad de uso y capacidad para manejar estacionalidades múltiples, días festivos y cambios en la tendencia. Este modelo resultó de interés para validar la estructura temporal de los datos antes de aplicar modelos más complejos.

Cada uno de estos modelos fue entrenado y validado utilizando el conjunto de datos consolidado de ventas e inversión publicitaria, y se compararon mediante

métricas como MAE (error absoluto medio), RMSE (raíz del error cuadrático medio) y MAPE (error porcentual absoluto medio), con el fin de seleccionar el que mejor se adaptara a las necesidades de pronóstico de Latech.

2.3. Tratamiento de datos (herramientas)

En esta sección se describen los procesos y herramientas utilizadas para la limpieza, transformación y análisis de los datos, así como los recursos externos desarrollados por terceros que resultaron fundamentales para la obtención y procesamiento de la información.

Bibliotecas para procesamiento y análisis de datos

- Pandas [17]: para la manipulación y transformación de datos tabulares, incluyendo operaciones de filtrado, agrupamiento y combinación de datasets.
- NumPy [18]: utilizado para operaciones numéricas y manejo eficiente de arreglos multidimensionales.
- Scikit-learn [19]: empleada para el preprocesamiento de datos (escalado, codificación de variables categóricas) y la implementación de modelos clásicos de machine learning.

Bibliotecas para visualización

- Matplotlib [20] y Seaborn [21]: para la generación de gráficos estáticos que facilitaron la identificación de patrones, tendencias y valores atípicos.
- Plotly [22]: utilizado para la creación de visualizaciones interactivas dentro de los notebooks.

Plataformas y APIs externas

- Shopify API [7]: para la extracción automatizada de datos históricos de ventas, productos y transacciones.
- Triple Whale API [8]: para la obtención de datos de inversión publicitaria desglosados por plataforma y campaña.
- PostgreSQL [23]: sistema de gestión de bases de datos utilizado para el almacenamiento estructurado de los datos consolidados.

Capítulo 3

Diseño e implementación

En este capítulo se describen los criterios utilizados para la construcción del desarrollo y la arquitectura definida para la solución. Se presenta la estructura general del sistema, las decisiones de diseño adoptadas y los componentes que permiten integrar fuentes de datos externas, procesarlas y generar pronósticos confiables de ventas.

3.1. Arquitectura del sistema

La arquitectura diseñada para el sistema de predicción de ventas se basa en un flujo de procesamiento secuencial y automatizado que conecta las fuentes de datos externas con el entorno interno del cliente. El diseño se orientó por tres criterios principales:

- Centralización y coherencia de datos, se priorizó la unificación de múltiples fuentes (ventas, comportamiento de usuarios, inversión en publicidad).
- Escalabilidad operativa que permita que el sistema integre nuevos canales, nuevas métricas o nuevos modelos sin alterar la estructura existente.
- Procesos reproducibles y auditables para asegurar que cada etapa sea trazable y que el sistema pueda ser mantenido o ampliado por equipos técnicos futuros.

El sistema se organiza en una arquitectura por capas que separa claramente las responsabilidades, desde la obtención de los datos hasta la entrega del pronóstico al usuario final. Estas capas son:

1. Capa de recolección de datos (Data Ingestion Layer)
2. Capa de procesamiento y transformación (ETL)
3. Capa de almacenamiento estructurado (Data Storage Layer)
4. Capa de modelado predictivo (Modeling Layer)
5. Capa de integración operativa mediante microservicios
6. Capa de visualización y consumo dentro de Inventory Tracker

Cada una de estas capas se comunica de manera acotada mediante APIs internas o a través de la base de datos para garantizar un bajo acoplamiento.

3.1.1. Capa de recolección de datos

Esta capa se encarga de conectarse periódicamente a APIs externas para obtener la información necesaria para entrenar y actualizar los modelos. La primera fuente es Shopify, que funciona como el pilar central de la información comercial del sistema. A través de su API es posible acceder a los históricos de ventas, incluyendo detalles como estado, valor total y descuentos. Además, cada orden incluye etiquetas que permiten distinguir si la compra corresponde a un cliente nuevo o recurrente, lo que posibilita analizar el comportamiento de los usuarios a lo largo del tiempo. Esta distinción es un insumo clave para caracterizar patrones de fidelidad, frecuencia de compra y recurrencia. A partir de la combinación de órdenes, etiquetas de comportamiento y series temporales de ventas, se logra reconstruir el ciclo completo de los clientes y diferenciar entre la demanda estable generada por suscriptores activos y la demanda variable asociada a compras espontáneas o impulsadas por campañas de marketing.

La segunda fuente de datos es Triple Whale, una plataforma que centraliza la información de inversión publicitaria proveniente de TikTok Ads [24], Instagram Ads [25], Facebook Ads [26] y Google Ads [27]. En este caso, su API no provee datos desagregados de campañas individuales, sino únicamente el monto diario total invertido en publicidad considerando todas las campañas activas. A pesar de esta limitación, esta información resulta suficiente para analizar la relación entre los niveles diarios de inversión publicitaria y las variaciones observadas en las ventas. De esta forma, el gasto diario consolidado funciona como un indicador de la presión publicitaria ejercida en cada jornada, lo que permite estudiar su impacto en el comportamiento de compra y en la demanda general del sistema.

3.1.2. Capa de procesamiento y transformación

Una vez obtenidos los datos desde las APIs externas, se realiza un proceso de transformación que normaliza y estructura la información. Las principales tareas incluyen:

- Limpieza de campos inconsistentes o incompletos.
- Conversión de formatos de fechas, monedas y valores numéricos.
- Enriquecimiento de datos combinando ventas, comportamiento de usuarios y gasto publicitario.
- Integración de información transaccional con métricas de suscripción.
- Control de duplicados y estandarización de claves primarias.

Dado que Shopify y Triple Whale estructuran sus datos de manera diferente, se construyó un esquema interno unificado que respeta la granularidad diaria necesaria para los modelos de predicción.

3.1.3. Capa de almacenamiento estructurado

Luego de su procesamiento, los datos se almacenan en una base de datos PostgreSQL diseñada específicamente para consultas analíticas y para servir como fuente unificada de información durante el entrenamiento y evaluación de los modelos. Dentro de esta capa se construye la tabla principal denominada orders,

en la cual se almacena la información proveniente de Shopify ya depurada y enriquecida. Esta tabla contiene las columnas fundamentales para caracterizar el comportamiento de compra de los usuarios: `created`, que registra la fecha de creación de cada orden; `totalPrice`, correspondiente al monto total pagado; `customerId`, que identifica al cliente; `lineItems`, donde se detalla cada producto incluido en la compra junto con sus cantidades; `channel`, que indica el canal por el cual ingresó la orden; `tags`, que permite distinguir si la compra corresponde a un cliente nuevo o recurrente mediante etiquetas provistas por Shopify; `orderNumberForCustomer`, que señala el número de orden que representa dentro del historial del cliente (por ejemplo, un valor igual a 1 implica un cliente nuevo); y `diffWeeksFromFirstPurchase`, que expresa la cantidad de semanas transcurridas desde la primera compra del usuario, permitiendo analizar patrones de frecuencia y retención.

A partir de esta tabla estructurada, se generan columnas derivadas mediante procesos de enriquecimiento en Python, con el objetivo de facilitar el análisis y preparar los datos para su uso en modelos predictivos. Entre estas variables se incluyen `created_weekday`, que identifica el día de la semana de cada orden; `created_month`, que permite estudiar estacionalidades mensuales; `unique_customers`, que calcula la cantidad de clientes distintos por día; `new_customers`, que contabiliza cuántos usuarios realizaron su primera compra dentro de cada fecha; y `returning_customers`, que contabiliza cuántos usuarios realizaron más de una compra. Estas nuevas columnas permiten construir vistas agregadas y analizar la evolución del comportamiento de los clientes en el tiempo.

Finalmente, otra tabla denominada `forecast` consolida la información diaria extraída de TripleWhale. Esta tabla incorpora, entre otras variables, el monto de inversión publicitaria bajo la columna `ad_spend`. La tabla contiene además otros campos utilizados por el sistema Inventory Tracker, derivados de los datos ya existentes; sin embargo, dichas columnas no forman parte del alcance del presente trabajo, ya que responden a necesidades operativas específicas del cliente y no intervienen en el proceso de modelado.

Este diseño facilita tanto el acceso para entrenamiento de modelos como la consulta rápida desde Inventory Tracker. En la figura 3.1 se muestran las dos tablas principales del trabajo con las columnas que se tomaron en cuenta para este proceso de almacenamiento.

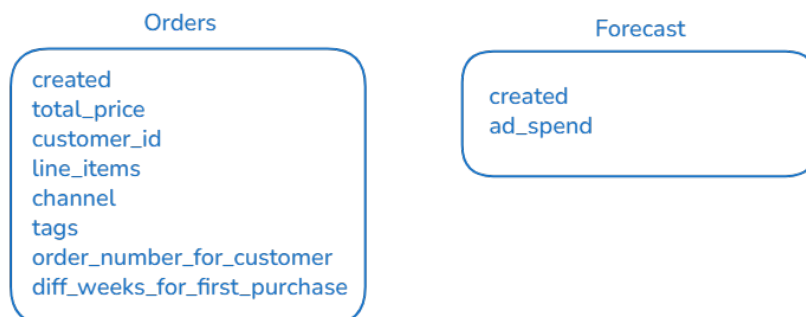


FIGURA 3.1. Diagrama Entidad-Relación. Muestra las dos tablas principales.

3.1.4. Capa de modelado predictivo

Esta capa es responsable del entrenamiento, evaluación y selección de los modelos de pronóstico de ventas. Se implementa un enfoque comparativo donde se ejecutan simultáneamente los modelos mencionados en el Capítulo 2.2 (SARIMA, *Exponential Smoothing*, *Random Forest*, XGBoost, LightGBM, LSTM y *Prophet*), con el objetivo de identificar el que ofrezca el mejor desempeño predictivo según las métricas definidas.

El proceso de modelado sigue las siguientes etapas:

Entrenamiento múltiple: todos los modelos son entrenados utilizando el mismo conjunto de datos históricos consolidado y enriquecido.

Evaluación y métricas: cada modelo es evaluado con la métrica RMSE (Raíz del Error Cuadrático Medio) para penalizar errores grandes que impactan significativamente en la planificación financiera y de producción.

Selección automática: el modelo que obtiene el menor valor de RMSE en el conjunto de validación es seleccionado automáticamente para su uso en producción.

Persistencia del modelo: una vez seleccionado, el modelo ganador es serializado y almacenado en un registro de modelos donde queda disponible para su uso en las predicciones futuras.

Exposición mediante API: el modelo guardado es integrado en un endpoint REST que forma parte del sistema de microservicios para que el sistema Inventory Tracker consulte las predicciones de ventas en tiempo real.

Este diseño no solo asegura que siempre se esté utilizando el modelo más preciso disponible, sino que también facilita la actualización periódica del mismo mediante reentrenamientos programados. Con cada actualización se mantiene la capacidad predictiva del sistema ante cambios en el comportamiento de las ventas o en las dinámicas de mercado.

3.1.5. Integración operativa con microservicios

El sistema se despliega mediante microservicios independientes, cada uno con su función específica:

Servicio de ingestión (cronjobs + conectores API).

Servicio de ETL.

Servicio de predicción.

Servicio de API interna para Inventory Tracker.

La comunicación se realiza mediante endpoints REST internos y colas de mensajería cuando se requieren procesos asíncronos.

Este enfoque facilita:

Actualizaciones de componentes sin afectar el sistema completo.

Escalado independiente de módulos según su carga (por ejemplo, ingestión vs. predicción).

Aislamiento de fallas.

3.1.6. Integración en Inventory Tracker

El resultado final —las predicciones de ventas— se expone dentro de Inventory Tracker mediante una interfaz que permite:

Solicitar pronósticos para distintos horizontes temporales.

Visualizar ventas históricas junto con proyecciones.

Combinar la predicción con datos operativos del cliente (stock, producción, etc.).

Este componente cierra el ciclo de valor: la información generada por el sistema se transforma en una herramienta de apoyo para la gestión diaria.

3.1.7. Justificación global de la arquitectura

La arquitectura fue diseñada bajo los siguientes principios:

Modularidad, para permitir reemplazar o actualizar partes sin reestructurar toda la solución.

Escalabilidad, considerando el crecimiento en volumen de datos y potencial incorporación de nuevas plataformas.

Trazabilidad, indispensable para un sistema basado en machine learning.

Flexibilidad, permitiendo combinar modelos clásicos, modelos de ML y eventualmente servicios administrados en la nube.

3.1.8. Capa de adquisición

El sistema obtiene información desde dos fuentes principales:

Shopify, que provee datos históricos de las ventas a través de sus endpoints de órdenes. Cada orden incluye información detallada como fecha, cantidad, monto, productos vendidos y etiquetas que permiten identificar si corresponde a un usuario nuevo o recurrente. Estas etiquetas son esenciales para analizar el comportamiento de los clientes, ya que permiten distinguir patrones de compra, detectar cohortes, evaluar la retención y comprender la proporción de usuarios que realizan compras únicas versus compras repetidas.

Triple Whale, que entrega el monto de inversión publicitaria de las plataformas (Meta Ads, TikTok Ads, Google Ads, etc.) agrupadas por día.

Ambas integraciones se realizan mediante un proceso automatizado que consulta las APIs diariamente y almacena la información en una base de datos PostgreSQL[23] interna. Este proceso opera bajo un módulo ETL [28] donde se llevan a cabo tareas de validación, normalización y estandarización para garantizar la coherencia entre fuentes heterogéneas.

3.1.9. Capa de procesamiento y generación del dataset final

Sobre la base de datos unificada se aplica un módulo de procesamiento donde se construye el dataset de entrenamiento. Aquí se realizan:

agregaciones temporales (diarias o semanales),

creación de variables derivadas (lags, medias móviles, ratios de inversión),

identificación de picos de campañas,
señalización de eventos especiales (promociones, feriados, lanzamientos),
integración del estado de suscripciones activas e inactivas.

Este módulo permite encapsular toda la lógica de preparación del dataset, manteniéndolo desacoplado del motor de predicción para que se pueda actualizar fácilmente.

3.1.4 Motor de predicción

El motor de predicción está compuesto por un conjunto de modelos que pueden ejecutarse de manera flexible según los requerimientos. La arquitectura permite evaluar y comparar distintos enfoques:

Modelos clásicos: ARIMA, SARIMA, ETS.

Modelos basados en aprendizaje automático: Random Forest Regressor, Gradient Boosting.

Modelos basados en redes neuronales: RNN y LSTM.

Herramientas externas opcionales: Prophet, Amazon Forecast.

El diseño modular permite cambiar o actualizar el modelo sin afectar los demás componentes del sistema. El modelo seleccionado genera pronósticos sobre la demanda futura considerando tanto el historial de ventas como la inversión publicitaria y la dinámica de suscripciones.

3.1.5 API interna y visualización en Inventory Tracker

Los resultados del modelo se publican a través de una API interna utilizada por la plataforma Inventory Tracker. Esta API expone endpoints que permiten:

consultar los pronósticos generados,
obtener métricas auxiliares,
visualizar la contribución de variables,
actualizar manualmente ciertos parámetros.

Los pronósticos son mostrados en una vista dedicada dentro de Inventory Tracker, donde el personal de marketing y operaciones puede utilizarlos directamente para la planificación de producción y campañas.

3.1.6 Automatización mediante cronjobs

Para garantizar el funcionamiento continuo del sistema, se implementaron tareas programadas que ejecutan:

extracción de datos diaria,
actualización del dataset,
reentrenamiento periódico del modelo,
generación de nuevas predicciones,
invalidación y regeneración de caché en Inventory Tracker.

Esto asegura que el cliente cuente siempre con información actualizada sin intervención manual.

3.1.10. Base de datos unificada

Una vez obtenidos los datos, el sistema los almacena en una base de datos PostgreSQL diseñada específicamente para consultas analíticas. En esta etapa, se generan tablas fact y dimensiones que permiten relacionar ventas, campañas publicitarias, comportamiento de usuarios y dinámica de suscripciones. Este almacenamiento estructurado es fundamental tanto para la exploración inicial como para el entrenamiento del modelo, dado que provee consultas optimizadas y consistencia histórica.

3.1.11. Condiciones del trabajo

El desarrollo del presente trabajo se realizó bajo las siguientes condiciones:

- La empresa Latech proporcionó acceso completo y continuo a las APIs externas de Shopify y Triple Whale, lo que permitió obtener datos históricos y actualizados.
- Se contó con acceso al repositorio de código y a la infraestructura necesaria para integrar el módulo de predicción en el sistema existente Inventory Tracker.
- La calidad, integridad y consistencia de los datos obtenidos desde las plataformas externas fue suficiente para entrenar y validar los modelos de predicción.
- Durante el período de desarrollo no se produjeron cambios significativos en las políticas de acceso ni en la estructura de datos de las APIs utilizadas.
- No existieron restricciones legales o contractuales que impidieran el uso de los datos necesarios para el trabajo.

3.2. Análisis de datos

3.3. Desarrollo de modelos

3.4. Desarrollo de un framework modular

3.5. Despliegue con microservicios e integración con bases de datos

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Ensayos de modelos

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

4.2. Desempeño del modelo

4.3. Desempeño de la predicción

4.4. Comparación de algoritmos

4.5. Validación de cumplimiento de requerimientos

A continuación se detalla la descripción técnica y alcance correspondientes a cada uno de los requerimientos especificados anteriormente.

Requerimiento funcional 1

Para cumplir este requerimiento, se desarrolló un módulo de integración que:

- Establece conexión con la API de Shopify mediante credenciales *API Key* y *Access Token*.
- Obtiene y procesa los siguientes atributos mínimos: fecha de compra, identificador de producto, cantidad vendida, precio unitario y canal de venta.
- Permite especificar intervalos de fechas para la descarga de datos.
- Almacena los datos importados en una base de datos PostgreSQL destinada a su posterior uso en el modelado.
- Implementa validaciones y manejo de errores en caso de fallos de autenticación, pérdida de conexión o respuestas vacías.
- Registra la trazabilidad del proceso de importación mediante un archivo de log, incluyendo volumen de datos procesados y errores detectados.

- Verifica duplicidades para evitar el doble procesamiento de registros previamente importados.

Requerimiento funcional 2

Para satisfacer este requerimiento se desarrolló un módulo de integración que:

- Establece conexión con la API de Triple Whale con una clave de acceso provista por la organización.
- Recupera la información de inversión por fecha, campaña y plataforma publicitaria.
- Permite seleccionar y configurar el intervalo temporal de los datos a importar.
- Almacena los datos obtenidos en una base de datos PostgreSQL, manteniendo una estructura consistente con el modelo de análisis utilizado.
- Implementa mecanismos de manejo de errores ante fallos de autenticación, interrupciones en la conexión o respuestas inválidas provenientes de la API.
- Registra el detalle del proceso mediante un archivo de log, incluyendo la cantidad de registros importados y los errores detectados durante la ejecución.
- Permite ejecutar el proceso de importación tanto de forma manual como programada mediante tareas periódicas.
- Incluye validaciones para evitar la duplicación de registros en caso de importaciones sobre el mismo rango de fechas.

Requerimiento funcional 3

Para satisfacer este requerimiento se desarrolló un proceso de consolidación que integra los datos provenientes de Shopify (ventas) y Triple Whale (inversión publicitaria), y garantiza la correcta correspondencia temporal entre ambas fuentes. En particular:

- Se generó un único *dataset* en el que las ventas diarias y la inversión total diaria se vinculan a través del campo de fecha.
- Se realizó el alineamiento temporal de las fechas, y se tuvo en cuenta posibles diferencias de zona horaria entre ambas plataformas.
- En los casos en que alguna de las fuentes no presentaba información para una fecha determinada, se mantuvo el registro correspondiente utilizando valores nulos para evitar la pérdida de información histórica.
- El conjunto de datos final incluye las siguientes columnas: `fecha`, `ventas_diarias`, `inversion_diaria` y `plataforma`.
- Se aplicaron validaciones para detectar y corregir duplicados, inconsistencias o formatos inválidos en los registros procesados.
- El proceso de consolidación se diseñó de manera automatizada y reproducible para su ejecución periódica sin intervención manual.

- El *dataset* resultante se almacenó en un formato estructurado apto para ser consumido directamente en las etapas de modelado y entrenamiento.
- Se registraron las operaciones del proceso mediante archivos de log, incluyendo la cantidad total de registros consolidados y cualquier incidencia detectada durante la ejecución.

Requerimiento funcional 4

Para cumplir con este requerimiento se implementó un proceso de modelado y entrenamiento estructurado que incluyó las siguientes etapas:

- Se empleó el *dataset* consolidado, compuesto por variables de ventas y de inversión publicitaria, como fuente principal para el entrenamiento del modelo.
- El conjunto de datos fue dividido en subconjuntos de entrenamiento y validación, siguiendo una proporción aproximada de 80 % para entrenamiento y 20 % para validación.
- Se evaluaron distintos modelos de predicción utilizando métricas de error adecuadas para series temporales, tales como MAE, RMSE y MAPE, con el fin de comparar su desempeño.
- Se seleccionó como modelo final aquel que presentó el mejor desempeño sobre el conjunto de validación.
- El modelo entrenado quedó habilitado para generar predicciones futuras a partir de valores recientes de entrada.
- Se garantizó la reproducibilidad del proceso mediante la definición de un *pipeline* de entrenamiento que permite repetir la ejecución bajo las mismas configuraciones.
- El modelo seleccionado y sus parámetros finales fueron almacenados para su posterior uso dentro del sistema Inventory Tracker.
- Se documentó el proceso de entrenamiento de manera detallada, incluyendo la selección de variables, las técnicas de preprocesamiento aplicadas y los métodos de evaluación utilizados.
- Se realizó una validación visual comparando las predicciones generadas frente a los valores reales observados, mediante gráficos que permitieron analizar la coherencia del modelo respecto a la dinámica histórica de las ventas.

Requerimiento funcional 5

Para cumplir con este requerimiento se implementaron las siguientes funcionalidades:

- Las predicciones de ventas se muestran en la interfaz de Inventory Tracker junto a las fechas correspondientes.
- La visualización integra tanto las predicciones como los datos históricos de ventas para comparaciones temporales y análisis de tendencias.

- La información se presenta de manera clara y entendible, utilizando gráficos de líneas y tablas según corresponda.
- Los usuarios pueden seleccionar rangos de fechas específicos para observar predicciones detalladas de periodos concretos.
- Las predicciones se actualizan automáticamente al entrenarse un nuevo modelo o al actualizarse los datos de entrada y se garantiza que la información refleje siempre el estado más reciente.
- La interfaz muestra un indicador visual de la fecha y hora de generación de la última predicción.
- Se distingue claramente entre valores predichos y datos históricos que evitan confusiones en el análisis.
- La integración de las predicciones no afecta la funcionalidad ni el rendimiento general de la interfaz del módulo Inventory Tracker.
- El rendimiento de la interfaz se mantiene aceptable incluso cuando se manejan conjuntos de datos de gran tamaño.

Requerimiento funcional 6

Para cumplir con este requerimiento se implementaron las siguientes funcionalidades:

- Se incorporó un botón o enlace claramente identificado que permite la descarga de las predicciones en formato CSV.
- El archivo CSV generado incluye las fechas y los valores de predicción correspondientes.
- De manera opcional, el archivo puede incluir los datos históricos de ventas para permitir la comparación con las predicciones.
- El formato del CSV es compatible con herramientas comunes de análisis, con valores separados por comas y codificación UTF-8.
- El nombre del archivo contiene la fecha y hora de generación que lo identifica.
- La descarga se realiza correctamente en navegadores modernos, incluyendo Chrome y Firefox.
- El contenido del archivo refleja exactamente la información presentada en la interfaz del módulo de predicción.
- Si aún no existen predicciones generadas, el botón de descarga se muestra deshabilitado.

Requerimiento funcional 7

Para cumplir con este requerimiento se implementaron las siguientes funcionalidades:

- El sistema verifica automáticamente la integridad del *dataset* antes de cada entrenamiento del modelo.

- Si se detectan datos faltantes críticos como fechas sin registros de ventas o de inversión publicitaria se genera una alerta.
- La alerta incluye información detallada sobre el tipo de dato faltante (ventas, inversión, o ambos), el rango de fechas afectado y el nivel de severidad del impacto estimado.
- La alerta se muestra de forma visible dentro del sistema para que los responsables puedan tomar conocimiento inmediato.
- Se envía una notificación por correo electrónico al responsable del sistema, en caso de estar configurada esta opción.
- El sistema no bloquea el entrenamiento del modelo, pero advierte que la precisión de las predicciones puede verse afectada.
- La alerta desaparece únicamente cuando los datos faltantes son completados o cuando se marca como revisada manualmente.
- Se registra un log de todas las alertas emitidas, accesible desde una sección de administración o monitoreo del sistema.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Resultados obtenidos

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Trabajo futuro

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] George E. P. Box et al. *Time Series Analysis: Forecasting and Control*. 5th. Wiley, 2015.
- [2] Rob J Hyndman y George Athanasopoulos. *Forecasting: principles and practice*. 2nd. OTexts, 2018. URL: <https://otexts.com/fpp3/>.
- [3] Sepp Hochreiter y Jürgen Schmidhuber. «Long short-term memory». En: *Neural Computation*. Vol. 9. 8. MIT Press, 1997, págs. 1735-1780.
- [4] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [5] Leo Breiman. «Random forests». En: *Machine Learning* 45.1 (2001), págs. 5-32.
- [6] Kasun Bandara, Christoph Bergmeir y Slawek Smyl. «Forecasting sales with machine learning in e-commerce». En: *International Journal of Forecasting* (2020).
- [7] *Shopify API*. <https://shopify.dev/api>. Accedido: 2025-11-09.
- [8] *Triple Whale API*. <https://triplewhale.com/api>. Accedido: 2025-11-09.
- [9] *Amazon Forecast*. <https://aws.amazon.com/forecast/>. Accedido: 2025-11-09.
- [10] *Amazon Web Services (AWS)*. <https://aws.amazon.com/>. Accedido: 2025-11-09.
- [11] Sean J Taylor y Ben Letham. *Forecasting at scale*. Vol. 72. 1. Taylor & Francis, 2018, págs. 37-45.
- [12] *Meta for Developers*. <https://developers.facebook.com/>. Accedido: 2025-11-09.
- [13] *RandomForestRegressor — scikit-learn documentation*. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>. Accedido: 2025-11-23.
- [14] Jerome H. Friedman. *Greedy Function Approximation: A Gradient Boosting Machine*. <https://jerryfriedman.su.domains/ftp/trebst.pdf>. Accedido: 2025-11-23. 2001. DOI: [10.1214/aos/1013203451](https://doi.org/10.1214/aos/1013203451).
- [15] Rob J. Hyndman et al. *Forecasting with Exponential Smoothing: The State Space Approach*. Accedido: 2025-11-23. 2008. URL: https://www.academia.edu/76833440/Forecasting_with_Exponential_Smoothing_The_State_Space_Approach_by_Rob_J_Hyndman_Anne_B_Koehler_J_Keith_Ord_Ralph_D_Snyder.
- [16] Kyunghyun Cho et al. «Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation». En: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Accedido: 2025-11-23. ACL. 2014, págs. 1724-1734. URL: <https://arxiv.org/abs/1406.1078>.
- [17] Jeff Reback et al. «pandas: powerful Python data analysis toolkit». En: *Zenodo* (2020). DOI: [10.5281/zenodo.3509134](https://doi.org/10.5281/zenodo.3509134). URL: <https://pandas.pydata.org/>.
- [18] Charles R. Harris et al. «Array programming with NumPy». En: *Nature* 585.7825 (2020), págs. 357-362. DOI: [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2). URL: <https://numpy.org/doc/stable/>.

- [19] Fabian Pedregosa et al. «Scikit-learn: Machine learning in Python». En: *Journal of Machine Learning Research* 12 (2011), págs. 2825-2830. URL: <https://scikit-learn.org/stable/>.
- [20] John D. Hunter. *Matplotlib: A 2D graphics environment*. Vol. 9. 3. IEEE, 2007, págs. 90-95. URL: <https://matplotlib.org/>.
- [21] Michael L. Waskom. «Seaborn: statistical data visualization». En: *Journal of Open Source Software* 6.60 (2021), pág. 3021. DOI: [10.21105/joss.03021](https://doi.org/10.21105/joss.03021). URL: <https://seaborn.pydata.org/>.
- [22] Plotly Technologies Inc. *Plotly Python Open Source Graphing Library*. <https://plotly.com/python/>. Accedido: 2025-11-23. 2015.
- [23] The PostgreSQL Global Development Group. *PostgreSQL Documentation*. <https://www.postgresql.org/docs/current/>. Consultado: 23 de noviembre de 2025. 2024.
- [24] *TikTok for Business*. <https://business.tiktok.com/en/>. Accedido: 2025-11-23.
- [25] *Instagram for Business*. <https://business.instagram.com/>. Accedido: 2025-11-23.
- [26] *Facebook for Business*. <https://business.facebook.com/>. Accedido: 2025-11-23.
- [27] *Google Ads*. <https://ads.google.com/>. Accedido: 2025-11-23.
- [28] *¿Qué es el proceso ETL?* <https://azure.microsoft.com/es-es/resources/cloud-computing-dictionary/what-is-etl/>. Consultado: 23 de noviembre de 2025.